

corelatii intre  
**RADON SI CO<sub>2</sub>**  
in detectarea seismelor

**TANIA SASARAN**  
**BIANCA SZEKELY**  
**MARA VALEAN**  
**JACLINA-IANA BULAT**  
**MARK DOSZLOP**



## 1. INTRODUCERE

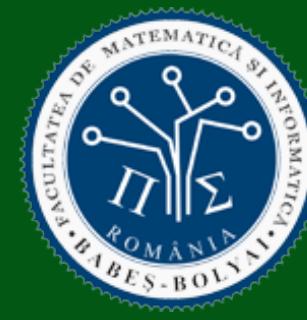
# CONTEXT

**In fiecare zi, cutremure devastatoare iau lumea prin surprindere, in toate partile lumii.**

**Ce ar putea sa imbunataseasca sansele autoritatilor de a prezice asemenea dezastre?**

**O solutie o reprezinta analiza emisiilor de radon si CO<sub>2</sub>, in zonele in care urmeaza sa fie cutremur. In urma studiilor, s-a dovedit cresterea probabilitatii dezastrelor seismice in urma concentratiilor ridicate ale acestor substante.**

**Mai mult, aceasta solutie poate fi augmentata cu ajutorul inteligentei artificiale, care poate prezice cu precizie aparitia unui cutremur, pe baza unor date de radon si CO<sub>2</sub>.**



TRADITIO ET EXCELLENTIA

DIGI 24 .ro

POLITICĂ ACTUALITATE ECONOMIE EXTERNE SPORT TV MAGAZIN MAI MULTE ▾

HOME > Știri > Actualitate > Alertă de cutremur în Turcia. Mai multe seisme de suprafață au zguduit regiunea Tokat

**Alertă de cutremur în Turcia. Mai multe seisme de suprafață au zguduit regiunea Tokat**

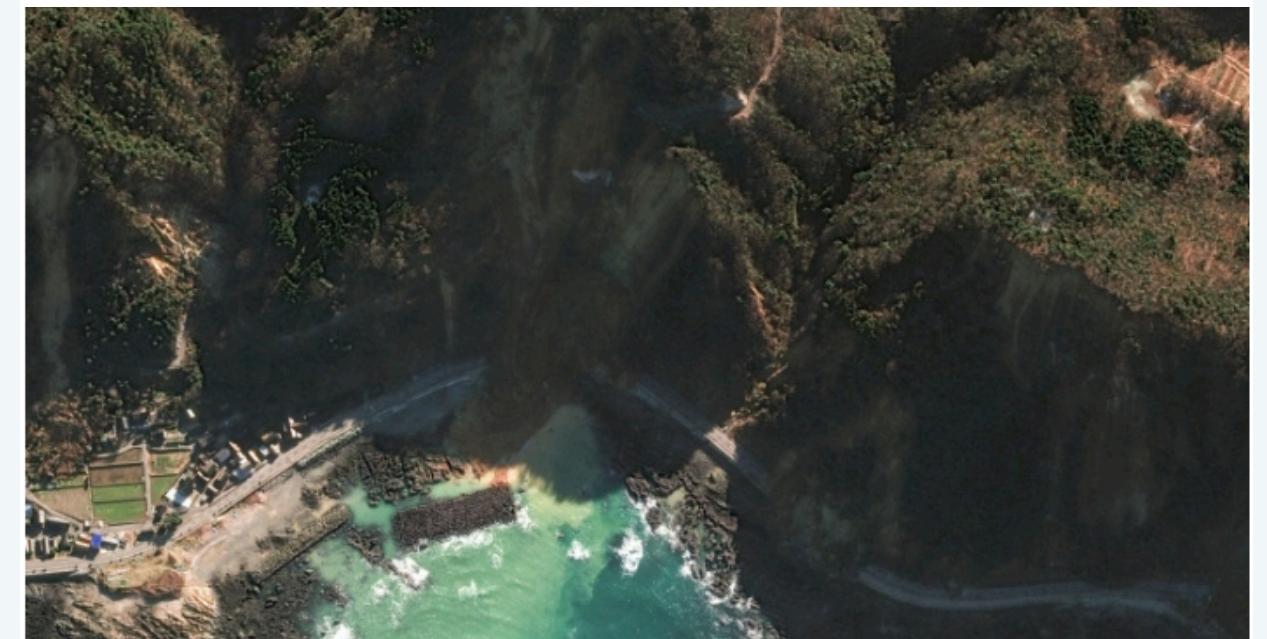


DIGI 24 .ro

POLITICĂ ACTUALITATE ECONOMIE EXTERNE SPORT TV MAGAZIN MAI MULTE ▾

HOME > Știri > Externe > Cutremurul din Japonia a lărgit cu 175 de metri linia de coastă a peninsulei Noto

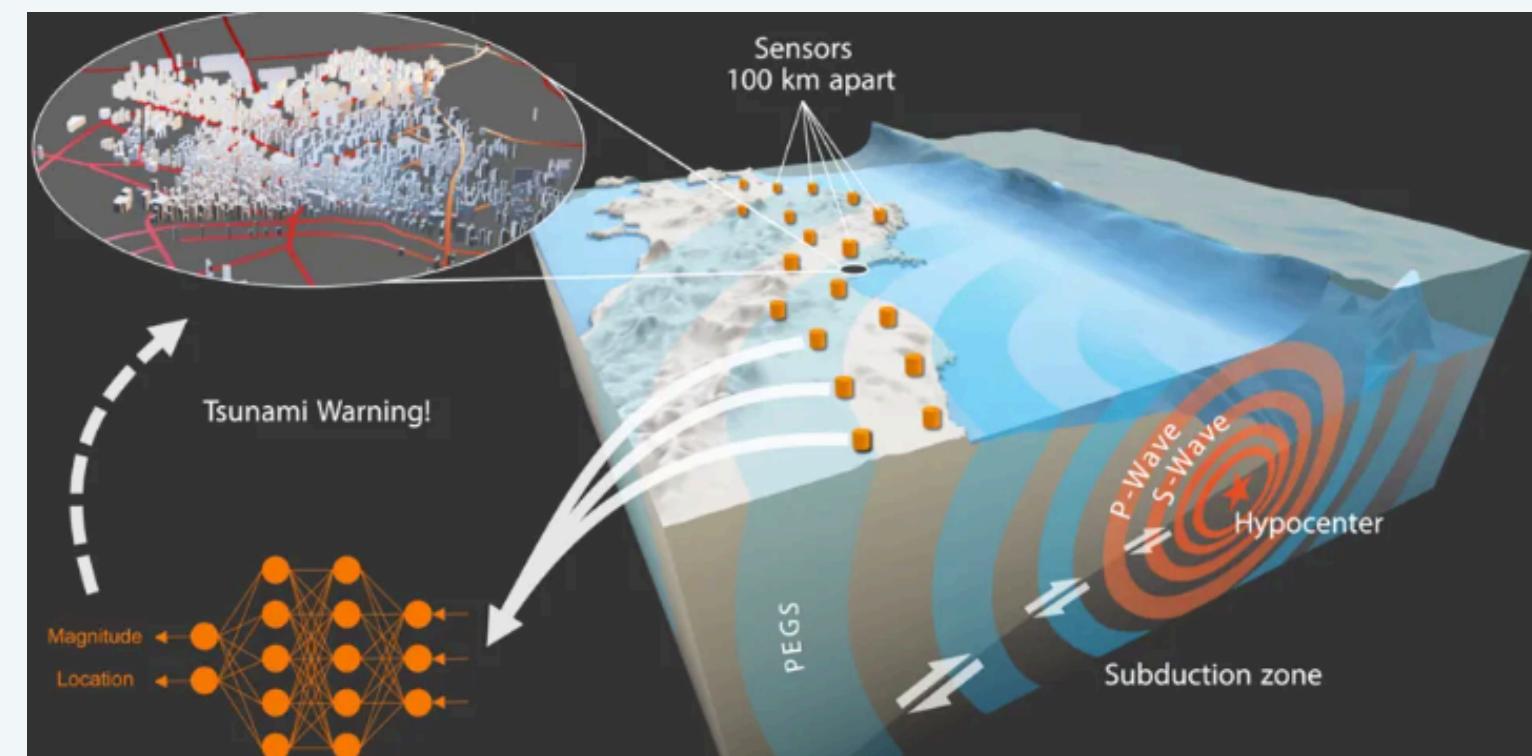
**Cutremurul din Japonia a lărgit cu 175 de metri linia de coastă a peninsulei Noto**



# AVANTAJE

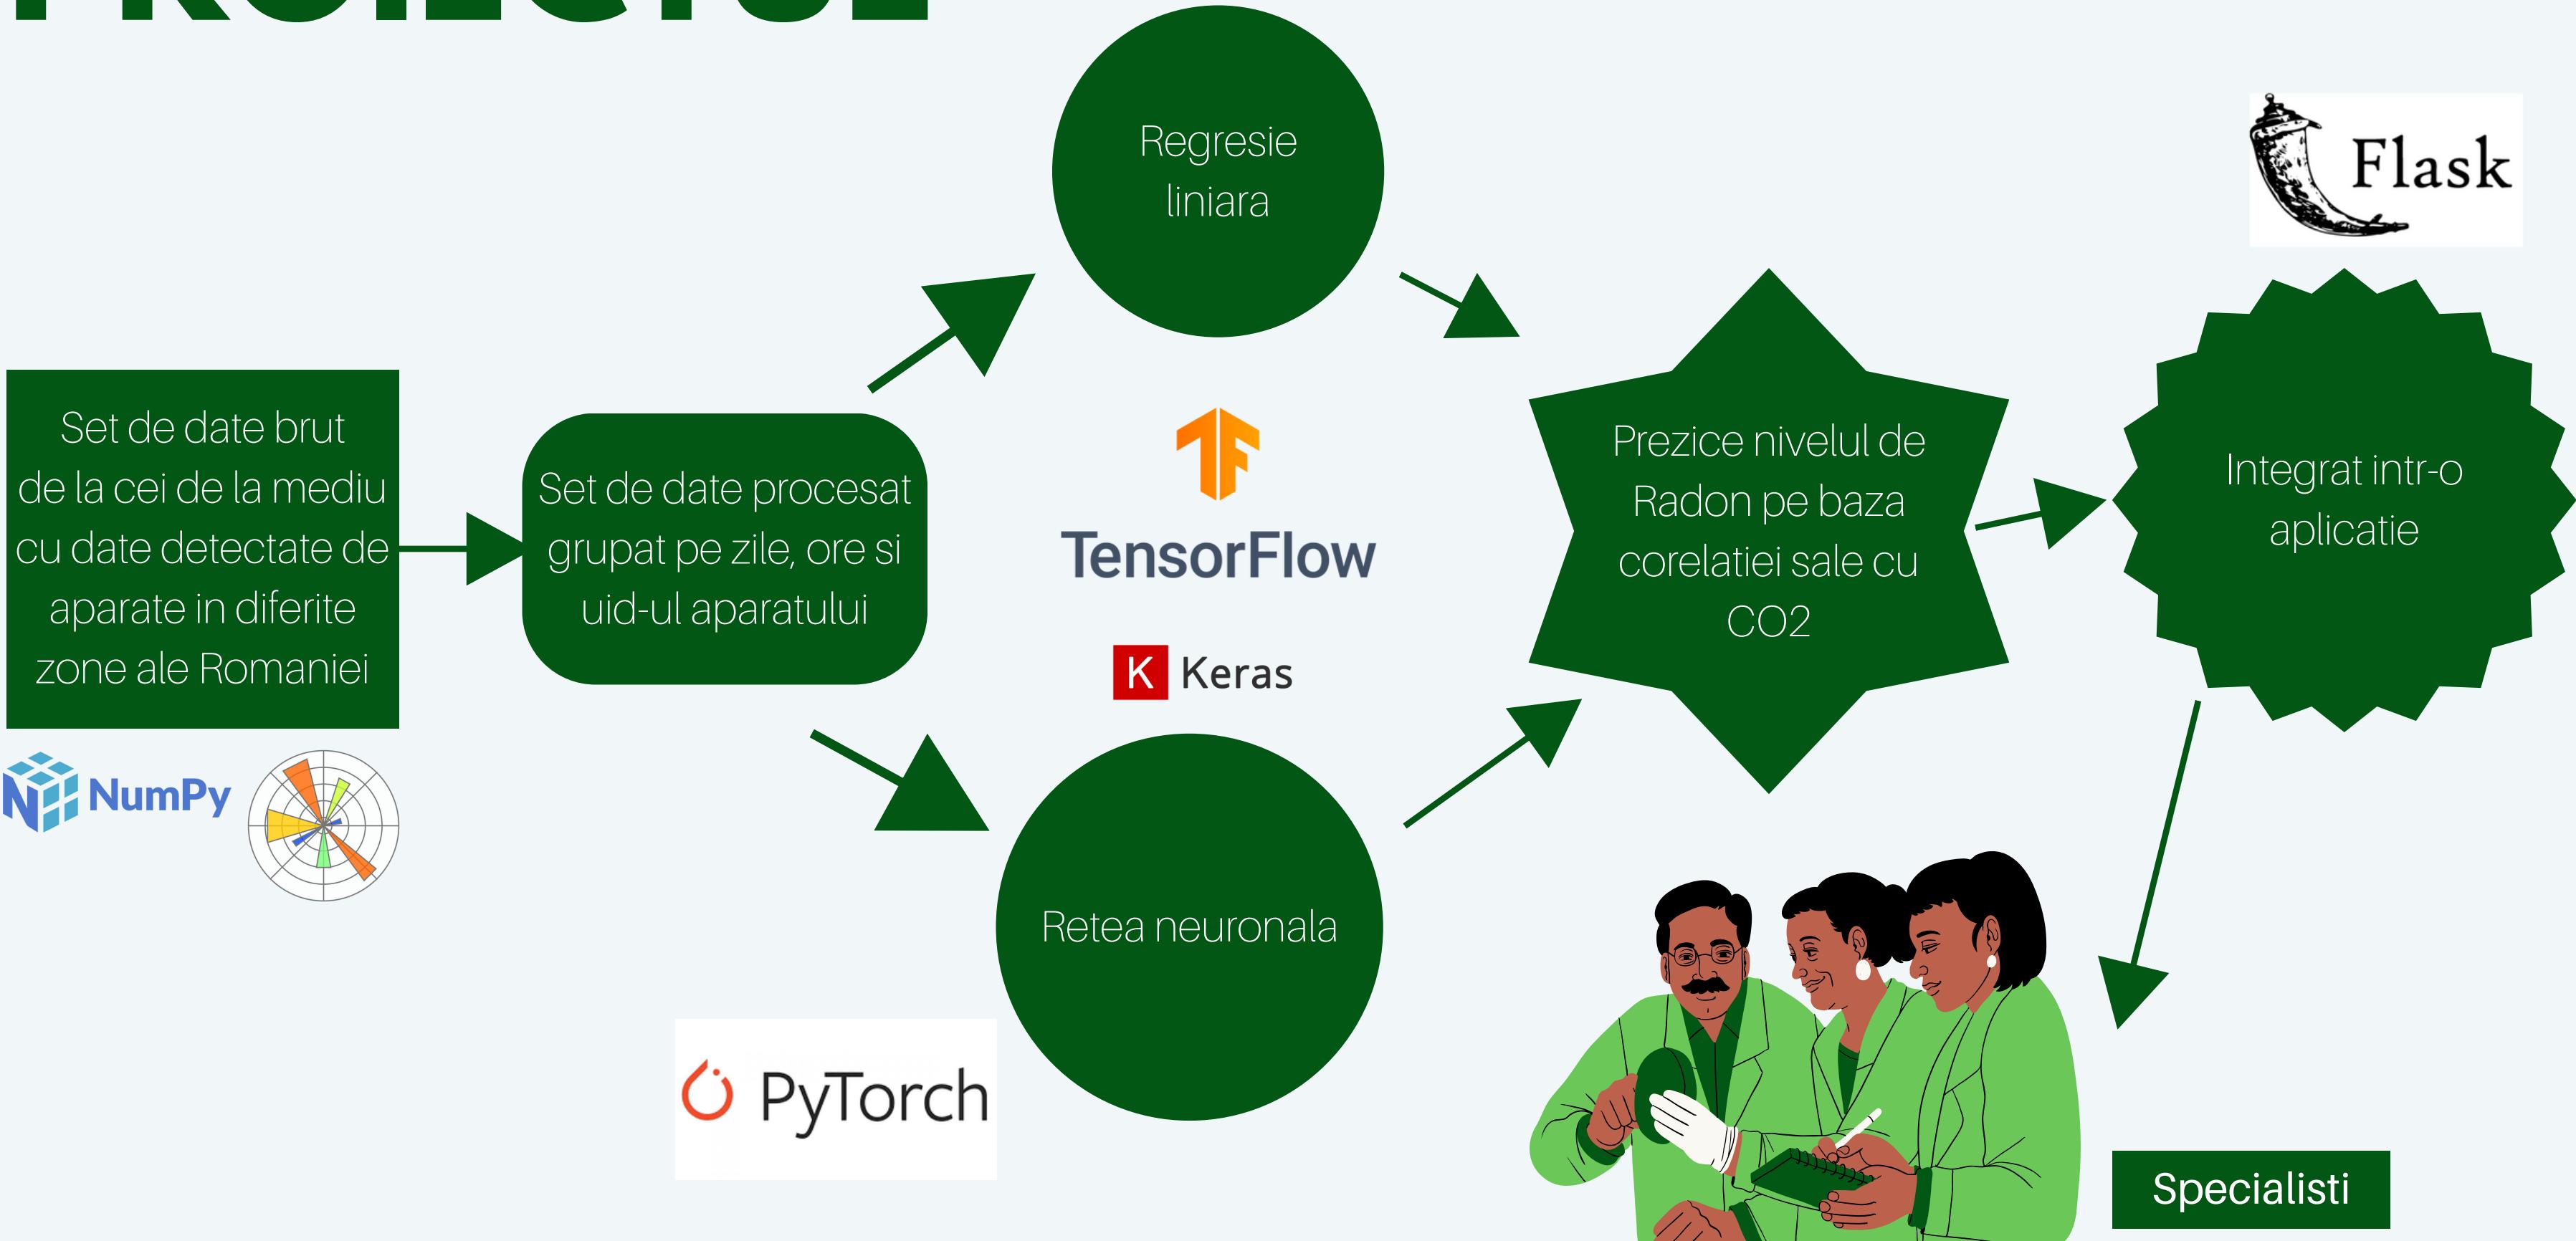
**Folosirea Inteligentei Artificiale în detectarea activitărilor seismice oferă niste avantaje semnificative:**

- Analiza datelor seismică și geologică folosind Inteligența Artificială identifică modele și tendințe ce semnalează riscul de cutremur sau activitate seismică neobișnuită.
- Predicții și avertismente timpurii folosind algoritmi permit estimări precise și avertizări rapide pentru cutremure iminente sau modificări ale activității seismice.
- Monitorizarea continuă folosind sisteme AI permite observarea în timp real a mișcărilor telurice și a altor parametri relevanți, facilitând intervenții rapide și ajustarea măsurilor de siguranță în funcție de evoluția situației.



## 1. INTRODUCERE

# PROIECTUL



## 2. METODE EXISTENTE DE REZOLVARE



# Analiza seriilor temporale de Radon pe 7 ani în zona Campi Flegrei folosind ANN

### Date utilizate

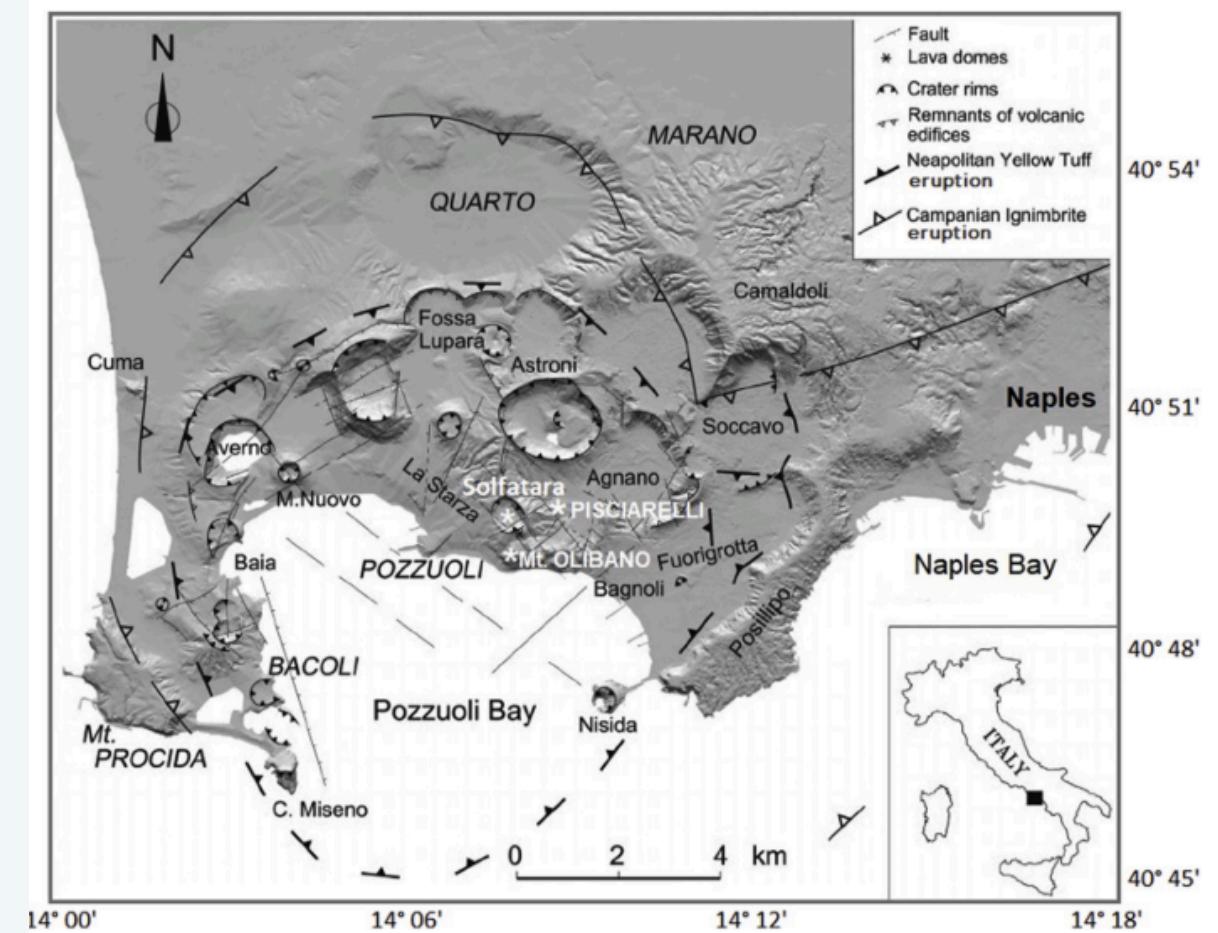
- Locatie: caldera vulcanică Campi Flegrei, Napoli, Italia
- Perioada: 1 iulie 2011 – 31 decembrie 2017
- Tipul datelor: set de date numeric, tabular

### Algoritm

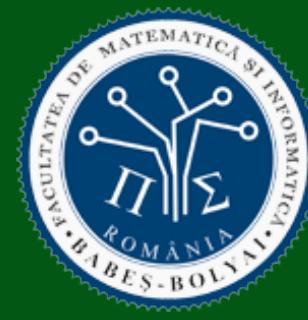
- Retea Neuronala Artificiala (ANN) cu un strat format din 6 neuroni, fiecare reprezentand un parametru diferit: emisiile de gaze din sol, activitatea seismică de fond, concentrația de CO<sub>2</sub>, temperatura, umiditatea relativă și presiunea

### Rezultate

- Coeficient de corelatie:  $p=0.82$
- Performanță: Distributia concentratiei de activitate a Radonului estimată de reteaua neurală a arătat o bună estimare și corelatie liniară între semnalele măsurate și cele antrenate.



## 2. METODE EXISTENTE DE REZOLVARE



# Clasificarea Anomalilor pentru Predicția Cutremurelor În Datele Seriilor Temporale de Radon Folosind Stacking și AAIF

### Date utilizate

- Locatie: zona de ruptură tectonică din Muzaffarabad, Kasmir, Pakistan
- Perioada: 1 martie 2017 – 28 februarie 2018
- Tipul datelor: concentratia de gaz Radon din sol măsurată în becquereli pe metru cub ( $\text{Bq}/\text{m}^3$ )

### Algoritm

- Metodologie cu două etape: un ansamblu de tip stacking și o funcție automata de identificare a anomalilor (AAIF)
- Primul strat foloseste metode precum Regresia Liniara și K-Nearest Neighbors pentru a prezice concentratia SRG și clasifică folosind o Masină de Suport Vectorial (SVM)
- Al doilea strat este funcția AAIF care clasifica seria temporală ca fiind activă/non-activă seismic în funcție de predicții

### Rezultate

- Acuratete la testare: intre 0.967 si 0.985 pentru diferite ferestre de timp
- Performanță: Acuratete ridicata in detectarea concentratiilor neobișnuite de radon

### 3. METODE FOLOSITE PENTRU REZOLVAREA PROBLEMEI

# SEQUENTIAL DNN



Utilizam un model secential cu 3 straturi dense:

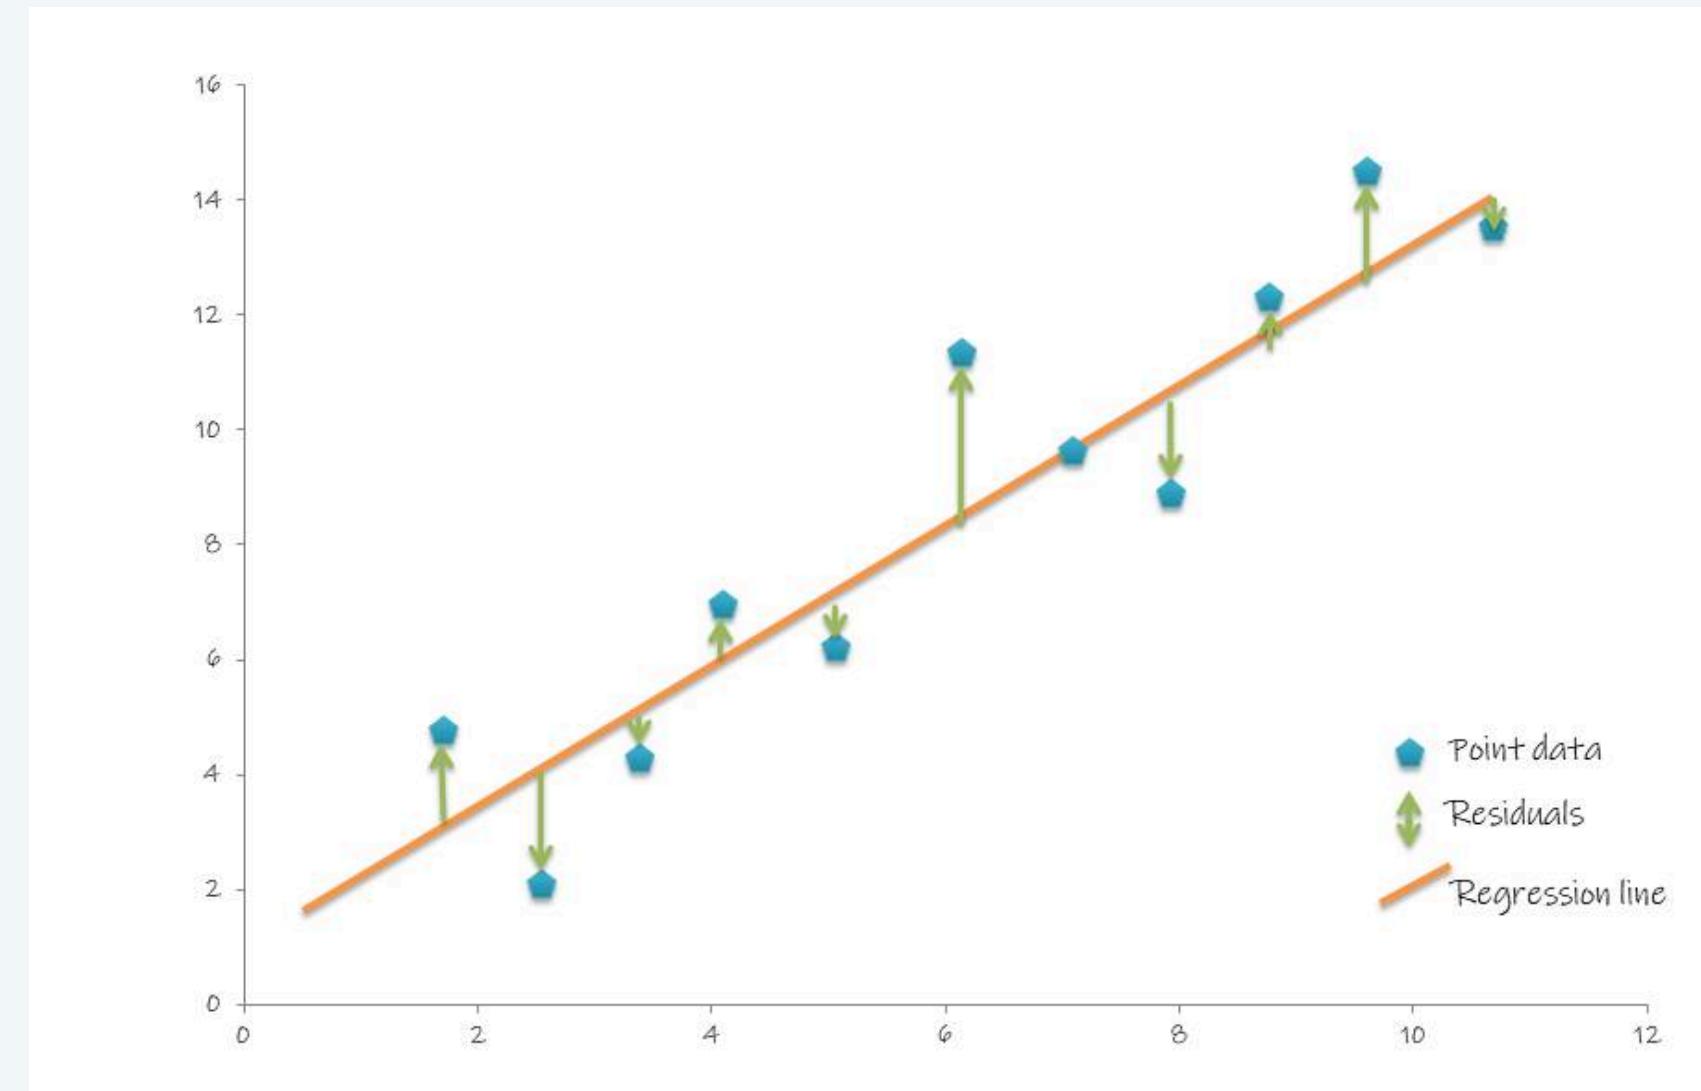
- primul strat: 32 de neuroni, activare ReLU
- al doilea strat: 16 neuroni, activare ReLU
- stratul de iesire: 1 neuron pentru predictie

Procesul de invatare si optimizare:

- optimizator: Adam cu descrestere exponentiala a ratei de invatare incepand de la 0.0001 si scăzând cu 0.9 la fiecare 1000 de pasi
- oprire timpurie: antrenamentul se opreste daca loss-ul nu se imbunatatestă pentru 10 epoci consecutive

Metrici folosite pentru evaluarea rezultatelor:

- MSE (eroarea medie patratica): media patratelor diferenței dintre valorile prezise și cele reale
- RMSE (radacina erorii medii patratice) : oferă o interpretare mai directă prin aceeași unitate de măsură ca datele initiale
- R-squared: măsoară cât de bine se potrivesc predicțiile cu valorile reale



## 4. REZULTATE EXPERIMENTALE OBTINUTE

# SET DE DATE



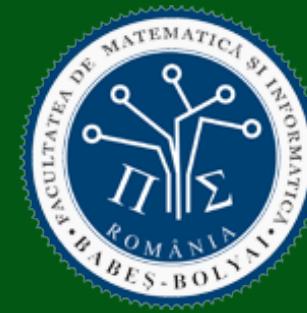
- În cadrul Laboratorului de Încercări Radon „Constantin Cosma” (LiRaCC) de la Universitatea Babeş-Bolyai au fost colectate date prin proiectul RadonControl pentru 25 de judeţe și câteva milioane de date măsurate în 2019 prin diverse aparete specializate.
- Date numerice salvate în format CSV



Stadiu initial	Stadiu Final
<p>Datele erau prezentate cu informații cuprinzând:</p> <ul style="list-style-type: none"><li>• timpul măsurării,</li><li>• UID-ul aparatului,</li><li>• gazul măsurat,</li><li>• valoarea măsurării,</li><li>• pornire-oprire alarma</li></ul>	<p>Am ales să grupam datele pe:</p> <ul style="list-style-type: none"><li>• ora, zi, luna și an</li><li>• UID-ul aparatelor pentru a putea prezice pe acele perioade de timp respectiv zonele cele mai predispuze</li></ul>

## 4. REZULTATE EXPERIMENTALE OBTINUTE

# REZULTATE OBTINUTE



TRADITIO ET EXCELLENTIA

### Parametri

### Metrici

### Performanta

#### Linear regression (exp. 1)

- parametrii default  
fit\_intercept=True,  
copy\_X=True,  
n\_jobs=None,  
positive=False

MSE: 2.704920541514603e-34  
RMSE: 1.6446642640717293e-17  
MAE: 4.6179672567598306e-18

- Rezultate bune

#### Sequential deep neural network (exp. 2)

- 3 layers  
first layer: Dense(32, activation='relu',  
input\_shape=(1,))  
second layer: Dense(16, activation='relu')  
third layer: Dense(1)

MSE: 2.366916421469567 x 10^-13  
RMSE: 4.865096526760355 x 10^-7  
R-squared: 0.9999998490441108

- Rezultate imbunatatite, mai  
multa flexibilitate si capacitate  
mai mare de modelare a datelor  
complexe. Punct negativ: nu e  
suportat in aplicatie

#### Neural Network for regression using pytorch (exp. 3)

- 3 layers  
first layer: Dense(32, activation='relu',  
input\_shape=(1,))  
second layer: Dense(16, activation='relu')  
third layer: Dense(1)

MSE: 8.723058709736048e-12,  
RMSE: 2.9534824715471136e-06,  
R-squared: 0.99999986137651

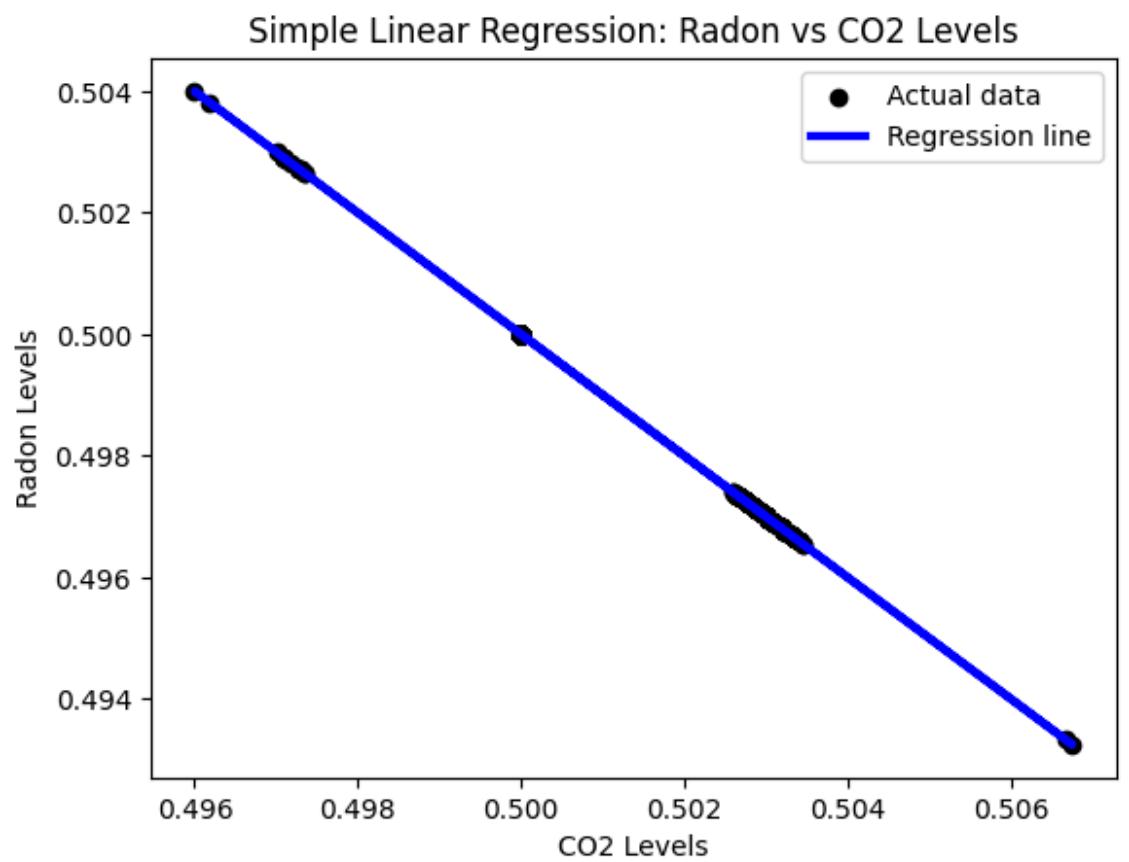
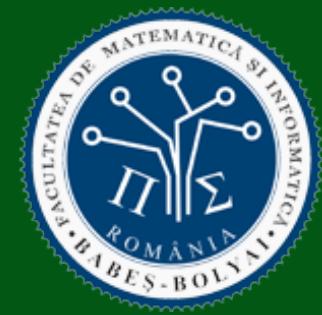
- Rezultate asemanatoare cu  
experimentul 2, dar integrabil in  
aplicatie

### De ce aceste analize?

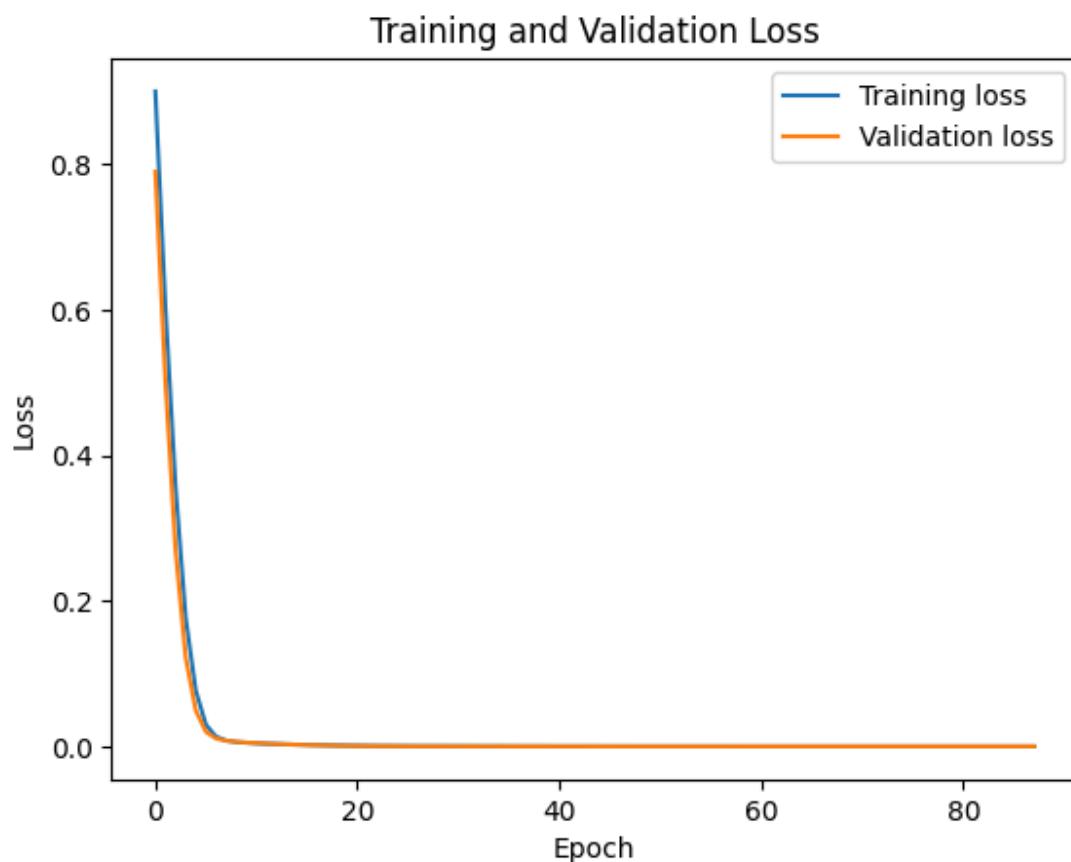
Rezultatele obtinute pot fi analizate de specialistii în domeniu pentru a putea corela și prezice când se întâmplă un cutremur bazat pe valorile de CO2 respectiv Radon.

## 4. REZULTATE EXPERIMENTALE OBTINUTE

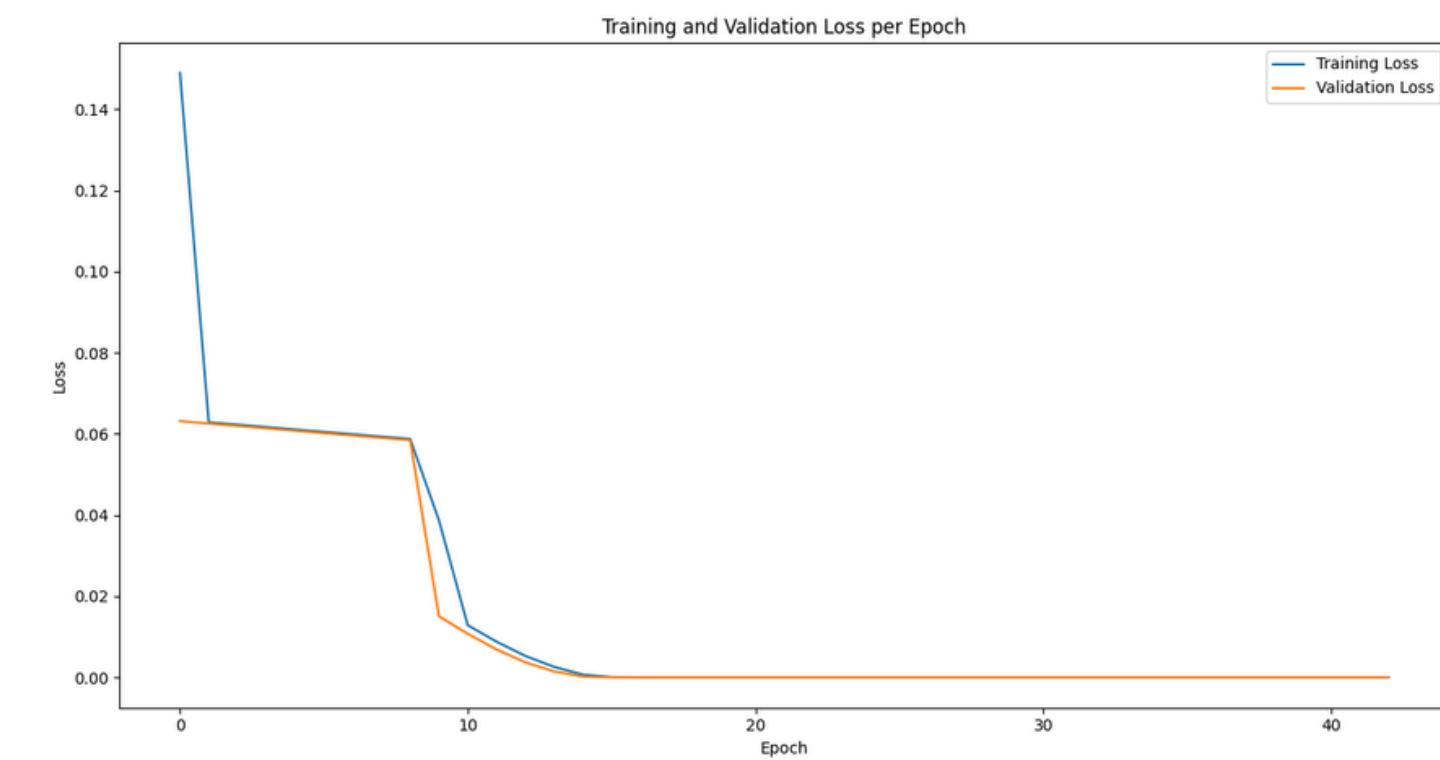
# REZULTATE OBTINUTE



Exp. 1



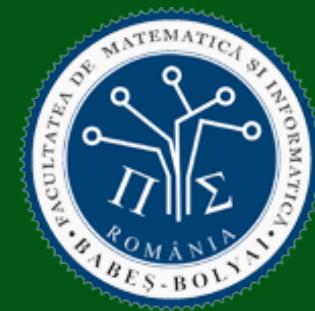
Exp. 2



Exp. 3

## 4. REZULTATE EXPERIMENTALE OBTINUTE

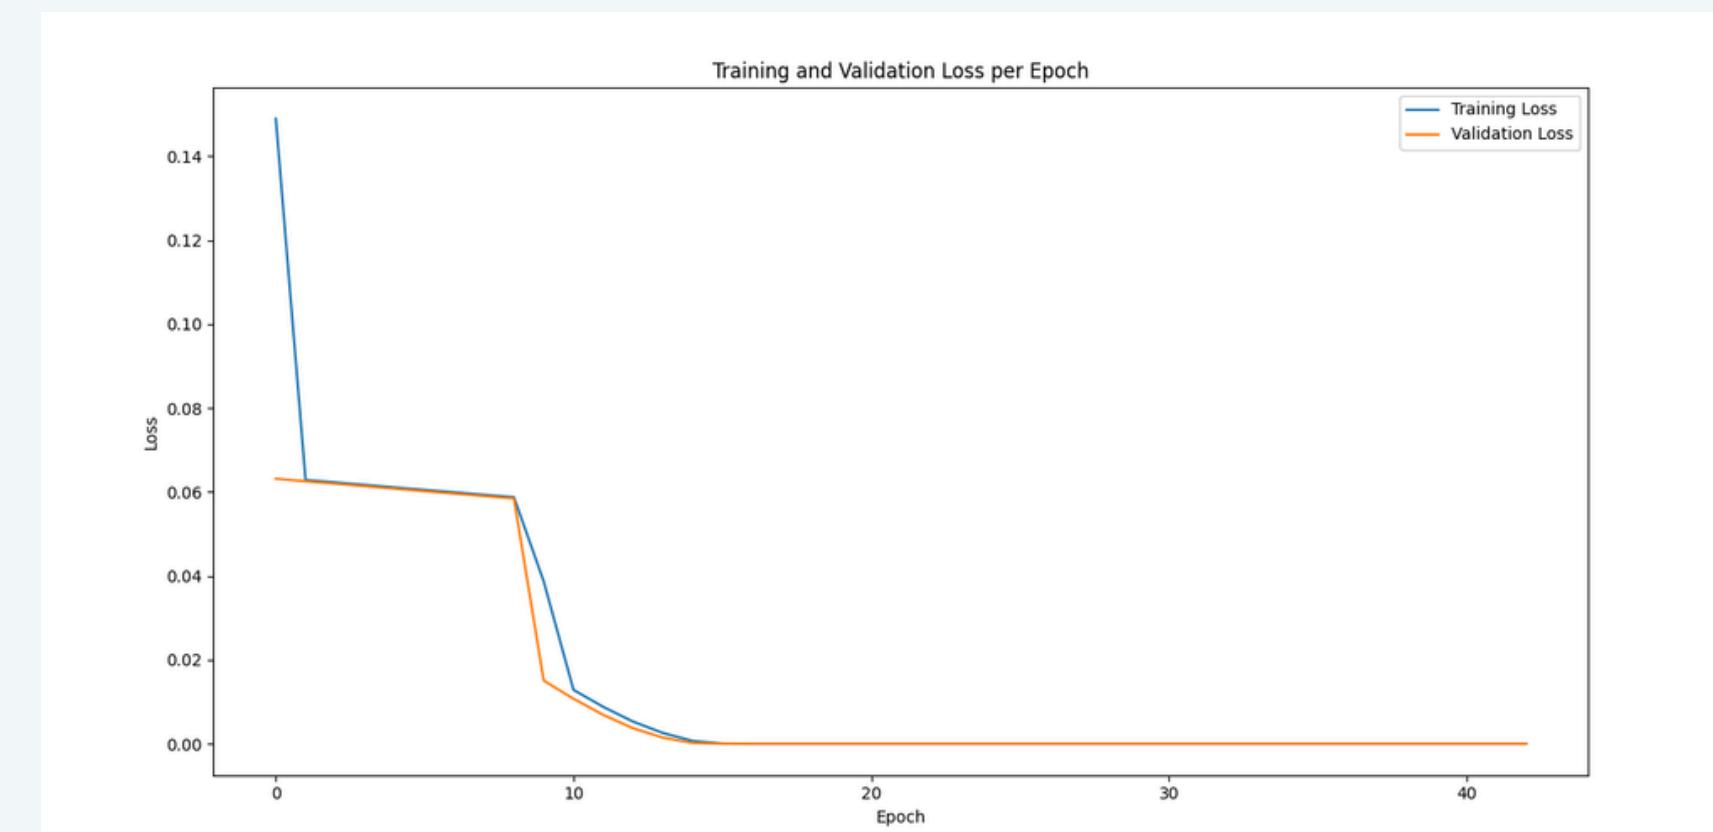
# ANALIZA REZULTATELOR



TRADITIO ET EXCELLENTIA

### Concluzii:

Performanța modelului de rețea neuronală din experimentul 2 este mai bună, apropiindu-se de o valoare perfectă pentru R-squared(1), care indică o potrivire aproape perfectă a modelului pe date. RMSE și MSE sunt foarte mici, ceea ce sugerează că erorile de predicție sunt neglijabile. Experimentul 3 este foarte asemănător cu experimentul 2, iar acesta permite integrarea cu aplicația.



### Valori metrici:

MSE:  $2.366916421469567 \times 10^{-13}$

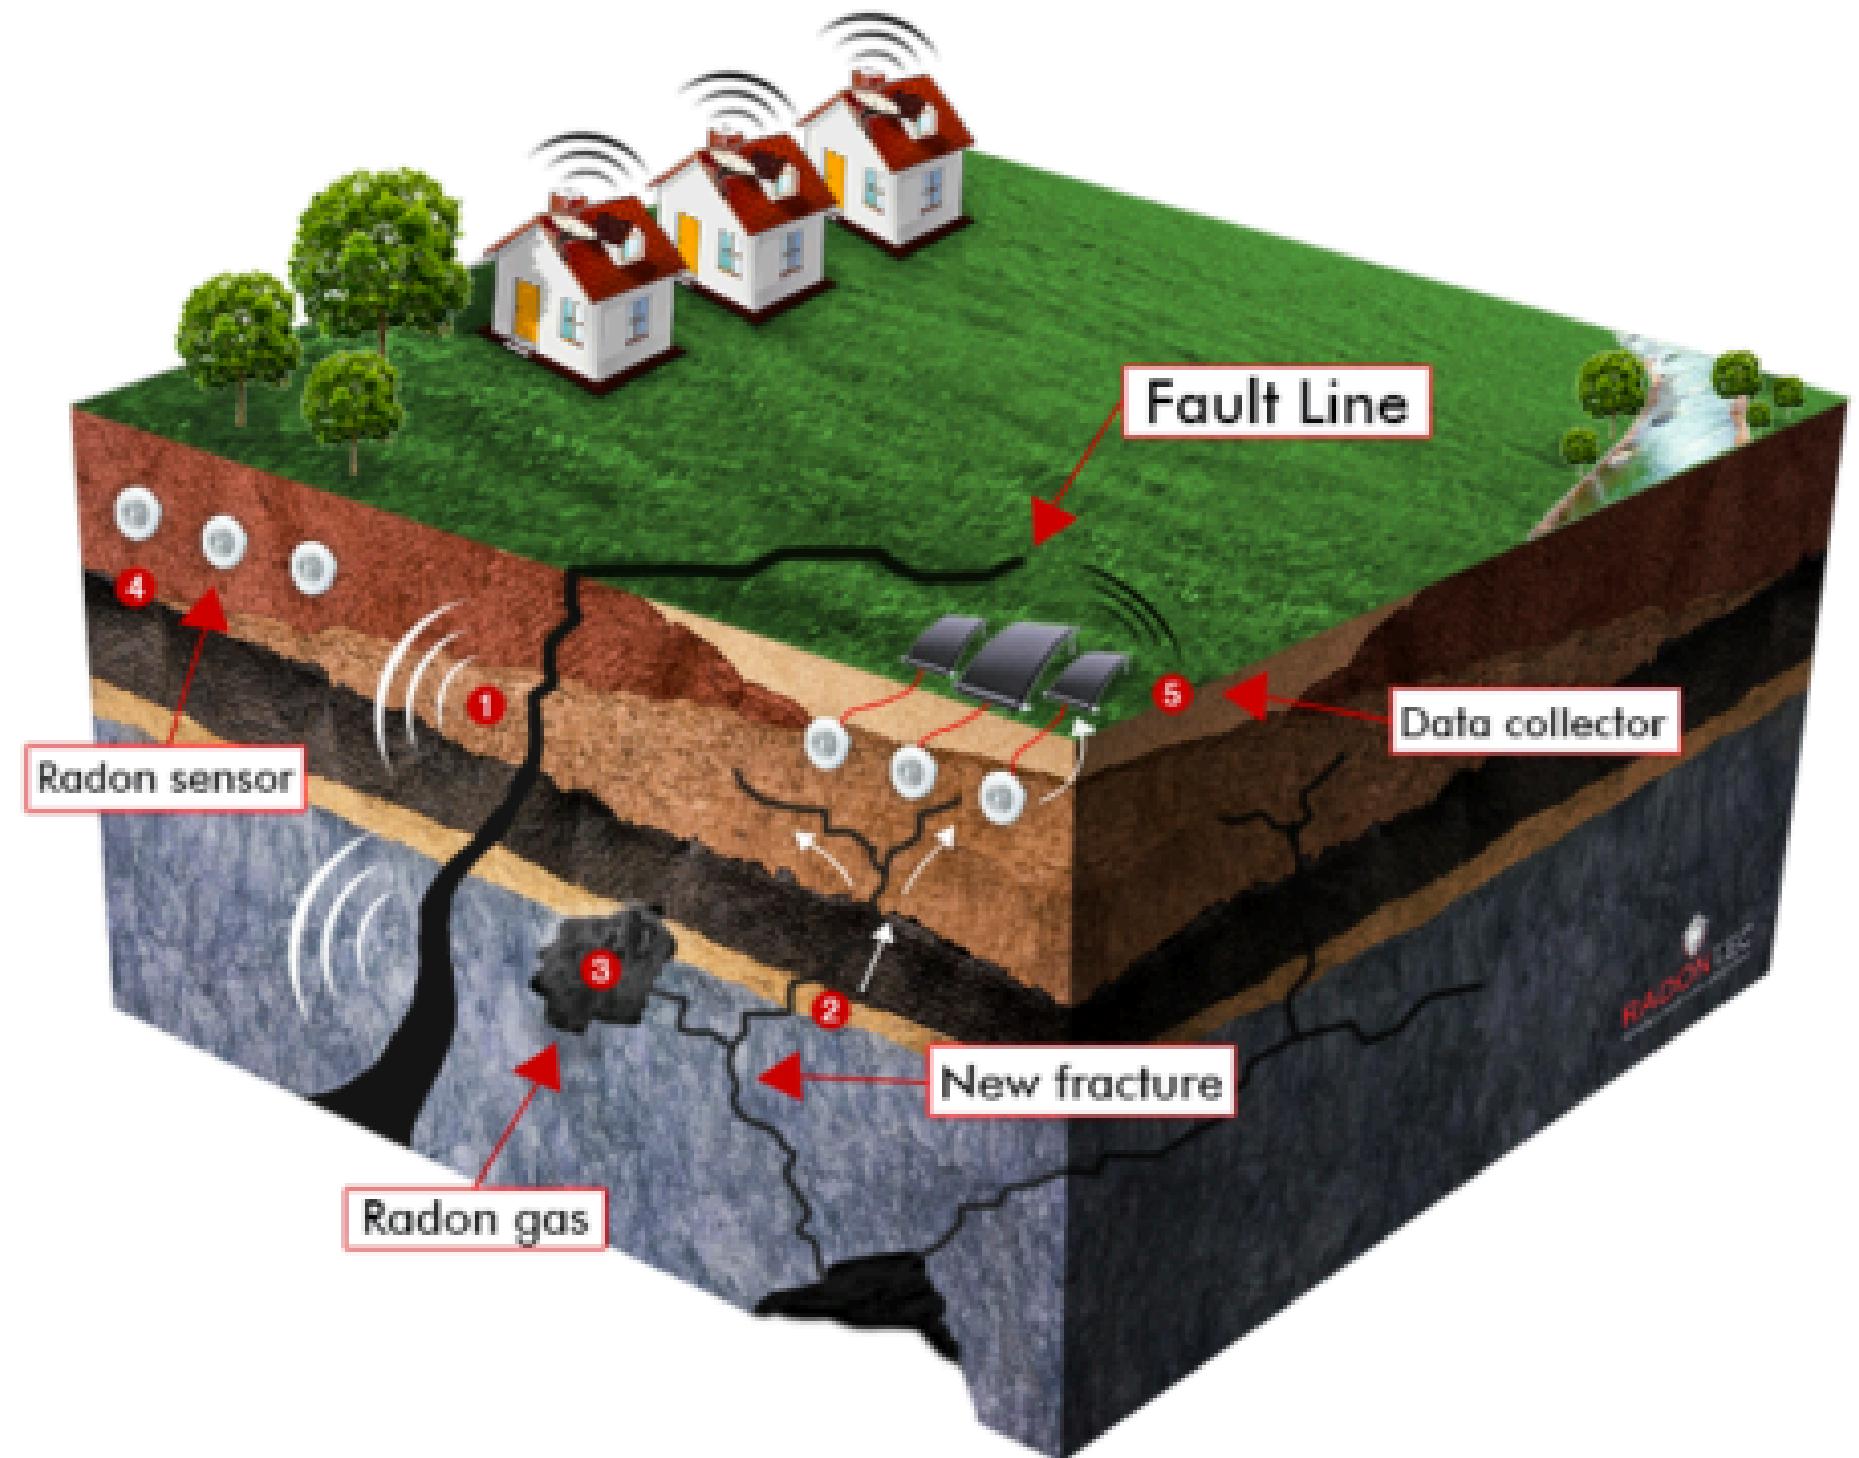
RMSE:  $4.865096526760355 \times 10^{-7}$

R-squared: 0.999998490441108

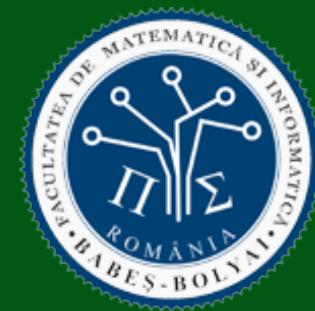
# CE AM PUTEA FACE MAI DEPARTE

Putem:

- dezvolta modele mai complexe care să poată detecta apariția cutremurelor (momentan depindem de specialiști să citească datele)
- îmbunătăți modelul curent
- analiza date și din afara României prin diverse colaborări



# LINK-URI SI CITATII



TRADITIO ET EXCELLENTIA

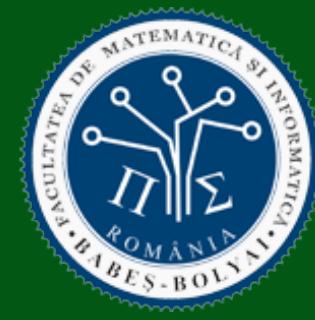
### Articole științifice:

1. Analysis of 7-years Radon time series at Campi Flegrei area (Naples, Italy) using artificial neural network method; *F. Ambrosino a b, C. Sabbarese a b, V. Roca b, F. Giudicepietro c, G. Chiodini*
2. Anomaly Classification For Earthquake Prediction In Radon Time Series Data Using Stacking And Automatic Anomaly Indication Function; *Adil Aslam Mir, Fatih Vehbi C, Elebi, Muhammad Rafique, M. R. I. Faruque, Mayeen Uddin Khandaker, Kimberlee Jane Kefarott, And Pervaiz Ahmad*
3. CO<sub>2</sub> and Radon Emissions as Precursors of Seismic Activity. *Earth Syst Environ 5; D'Incecco, S., Petraki, E., Prinotakis, G. et al.*

### Imagini:

- 1.<https://radontec.de/earthquake-early-warning-with-radon-sensor-technology>
- 2.<https://hatarilabs.com/ih-en/how-to-calculate-the-root-mean-square-error-rmse-of-an-interpolated-ph-raster>
- 3.<https://www.digi24.ro/stiri/externe/cutremurul-din-japonia-a-largit-cu-175-de-metri-linia-de-coasta-a-peninsulei-noto-2640627>
- 4.<https://www.digi24.ro/stiri/actualitate/alerta-de-cutremur-in-turcia-mai-multe-seisme-de-suprafata-au-zguduit-regiunea-tokat-2766009>
- 5.<https://www.times-standard.com/2024/02/17/lori-dengler-artificial-intelligence-in-the-earthquake-and-tsunami-world/>

# COD SURSA + CAPTURA



TRADITIO ET EXCELLENTIA

<https://github.com/taniasasaran/QORn>

### CO2 - Radon Correlation and Prediction

Enter CO2 value to predict radon value.

CO2:

Predict

#### Prediction Result

Predicted radon value: 4291.611328125

# CUM PUTEM PROTEJA FIINTELE DE CUTREMURE?

**TANIA SASARAN**  
**BIANCA SZEKELY**  
**MARA VALEAN**  
**JACLINA-IANA BULAT**  
**MARK DOSZLOP**

