

corelatii intre
RADON SI CO₂
in detectarea seismelor

TANIA SASARAN
BIANCA SZEKELY
MARA VALEAN
JACLINA-IANA BULAT
MARK DOSZLOP



1. INTRODUCERE

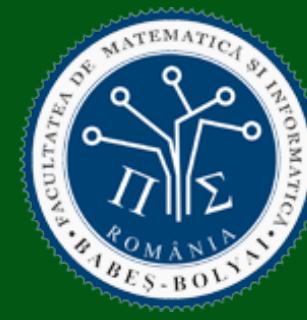
CONTEXT

In fiecare zi, cutremure devastatoare iau lumea prin surprindere, in toate partile lumii.

Ce ar putea sa imbunataseasca sansele autoritatilor de a prezice asemenea dezastre?

O solutie o reprezinta analiza emisiilor de radon si CO₂, in zonele in care urmeaza sa fie cutremur. In urma studiilor, s-a dovedit cresterea probabilitatii dezastrelor seismice in urma concentratiilor ridicate ale acestor substante.

Mai mult, aceasta solutie poate fi augmentata cu ajutorul inteligentei artificiale, care poate prezice cu precizie aparitia unui cutremur, pe baza unor date de radon si CO₂.



TRADITIO ET EXCELLENTIA

DIGI 24 .ro

POLITICĂ ACTUALITATE ECONOMIE EXTERNE SPORT TV MAGAZIN MAI MULTE ▾

HOME > Știri > Actualitate > Alertă de cutremur în Turcia. Mai multe seisme de suprafață au zguduit regiunea Tokat

Alertă de cutremur în Turcia. Mai multe seisme de suprafață au zguduit regiunea Tokat

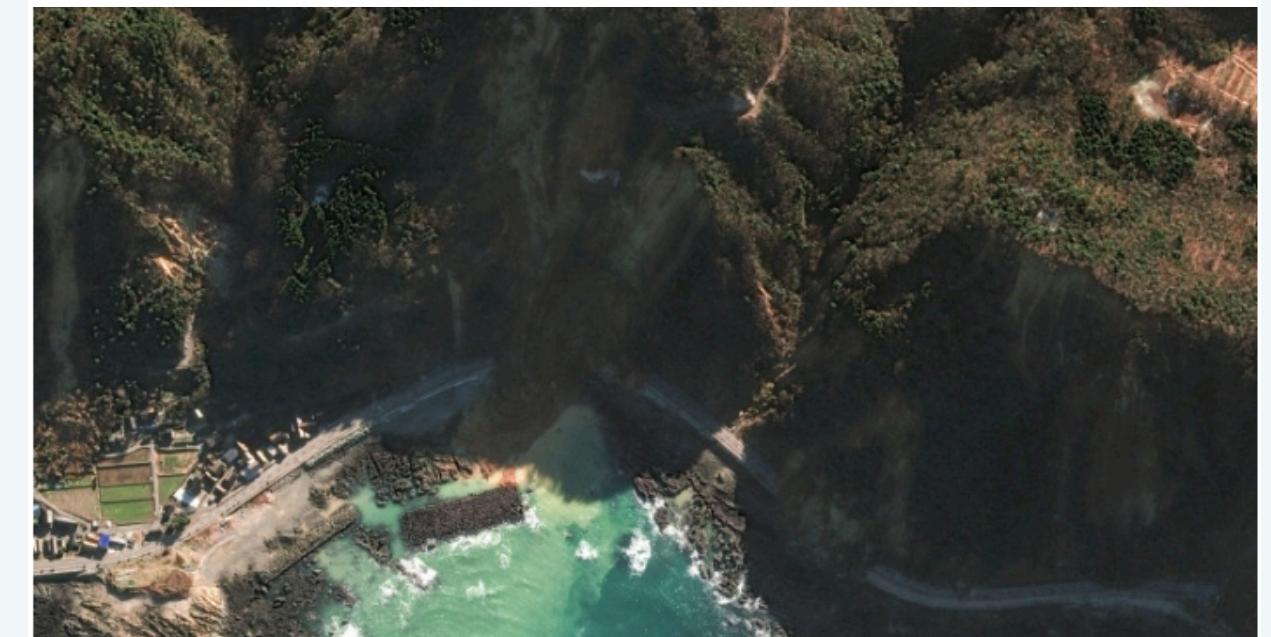


DIGI 24 .ro

POLITICĂ ACTUALITATE ECONOMIE EXTERNE SPORT TV MAGAZIN MAI MULTE ▾

HOME > Știri > Externe > Cutremurul din Japonia a lărgit cu 175 de metri linia de coastă a peninsulei Noto

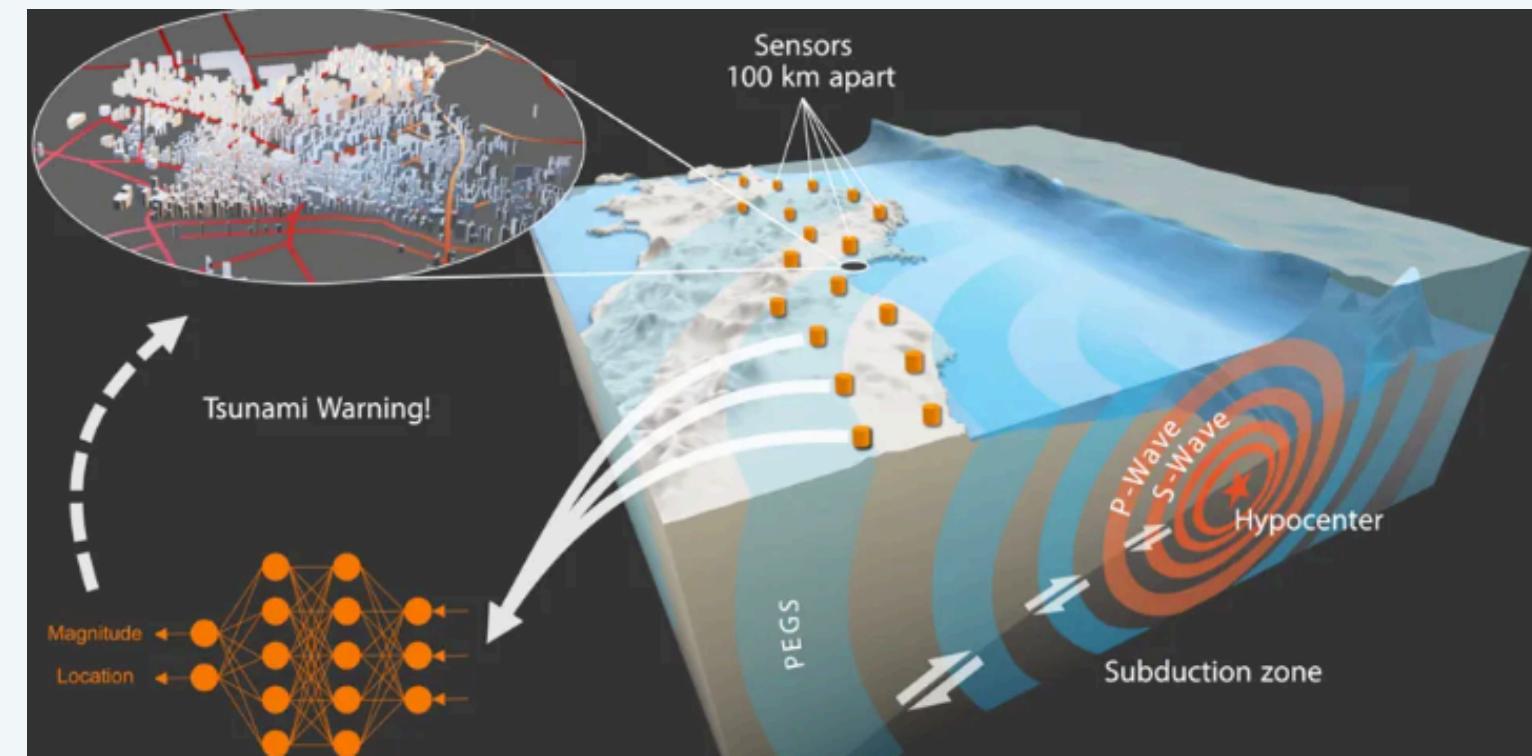
Cutremurul din Japonia a lărgit cu 175 de metri linia de coastă a peninsulei Noto



AVANTAJE

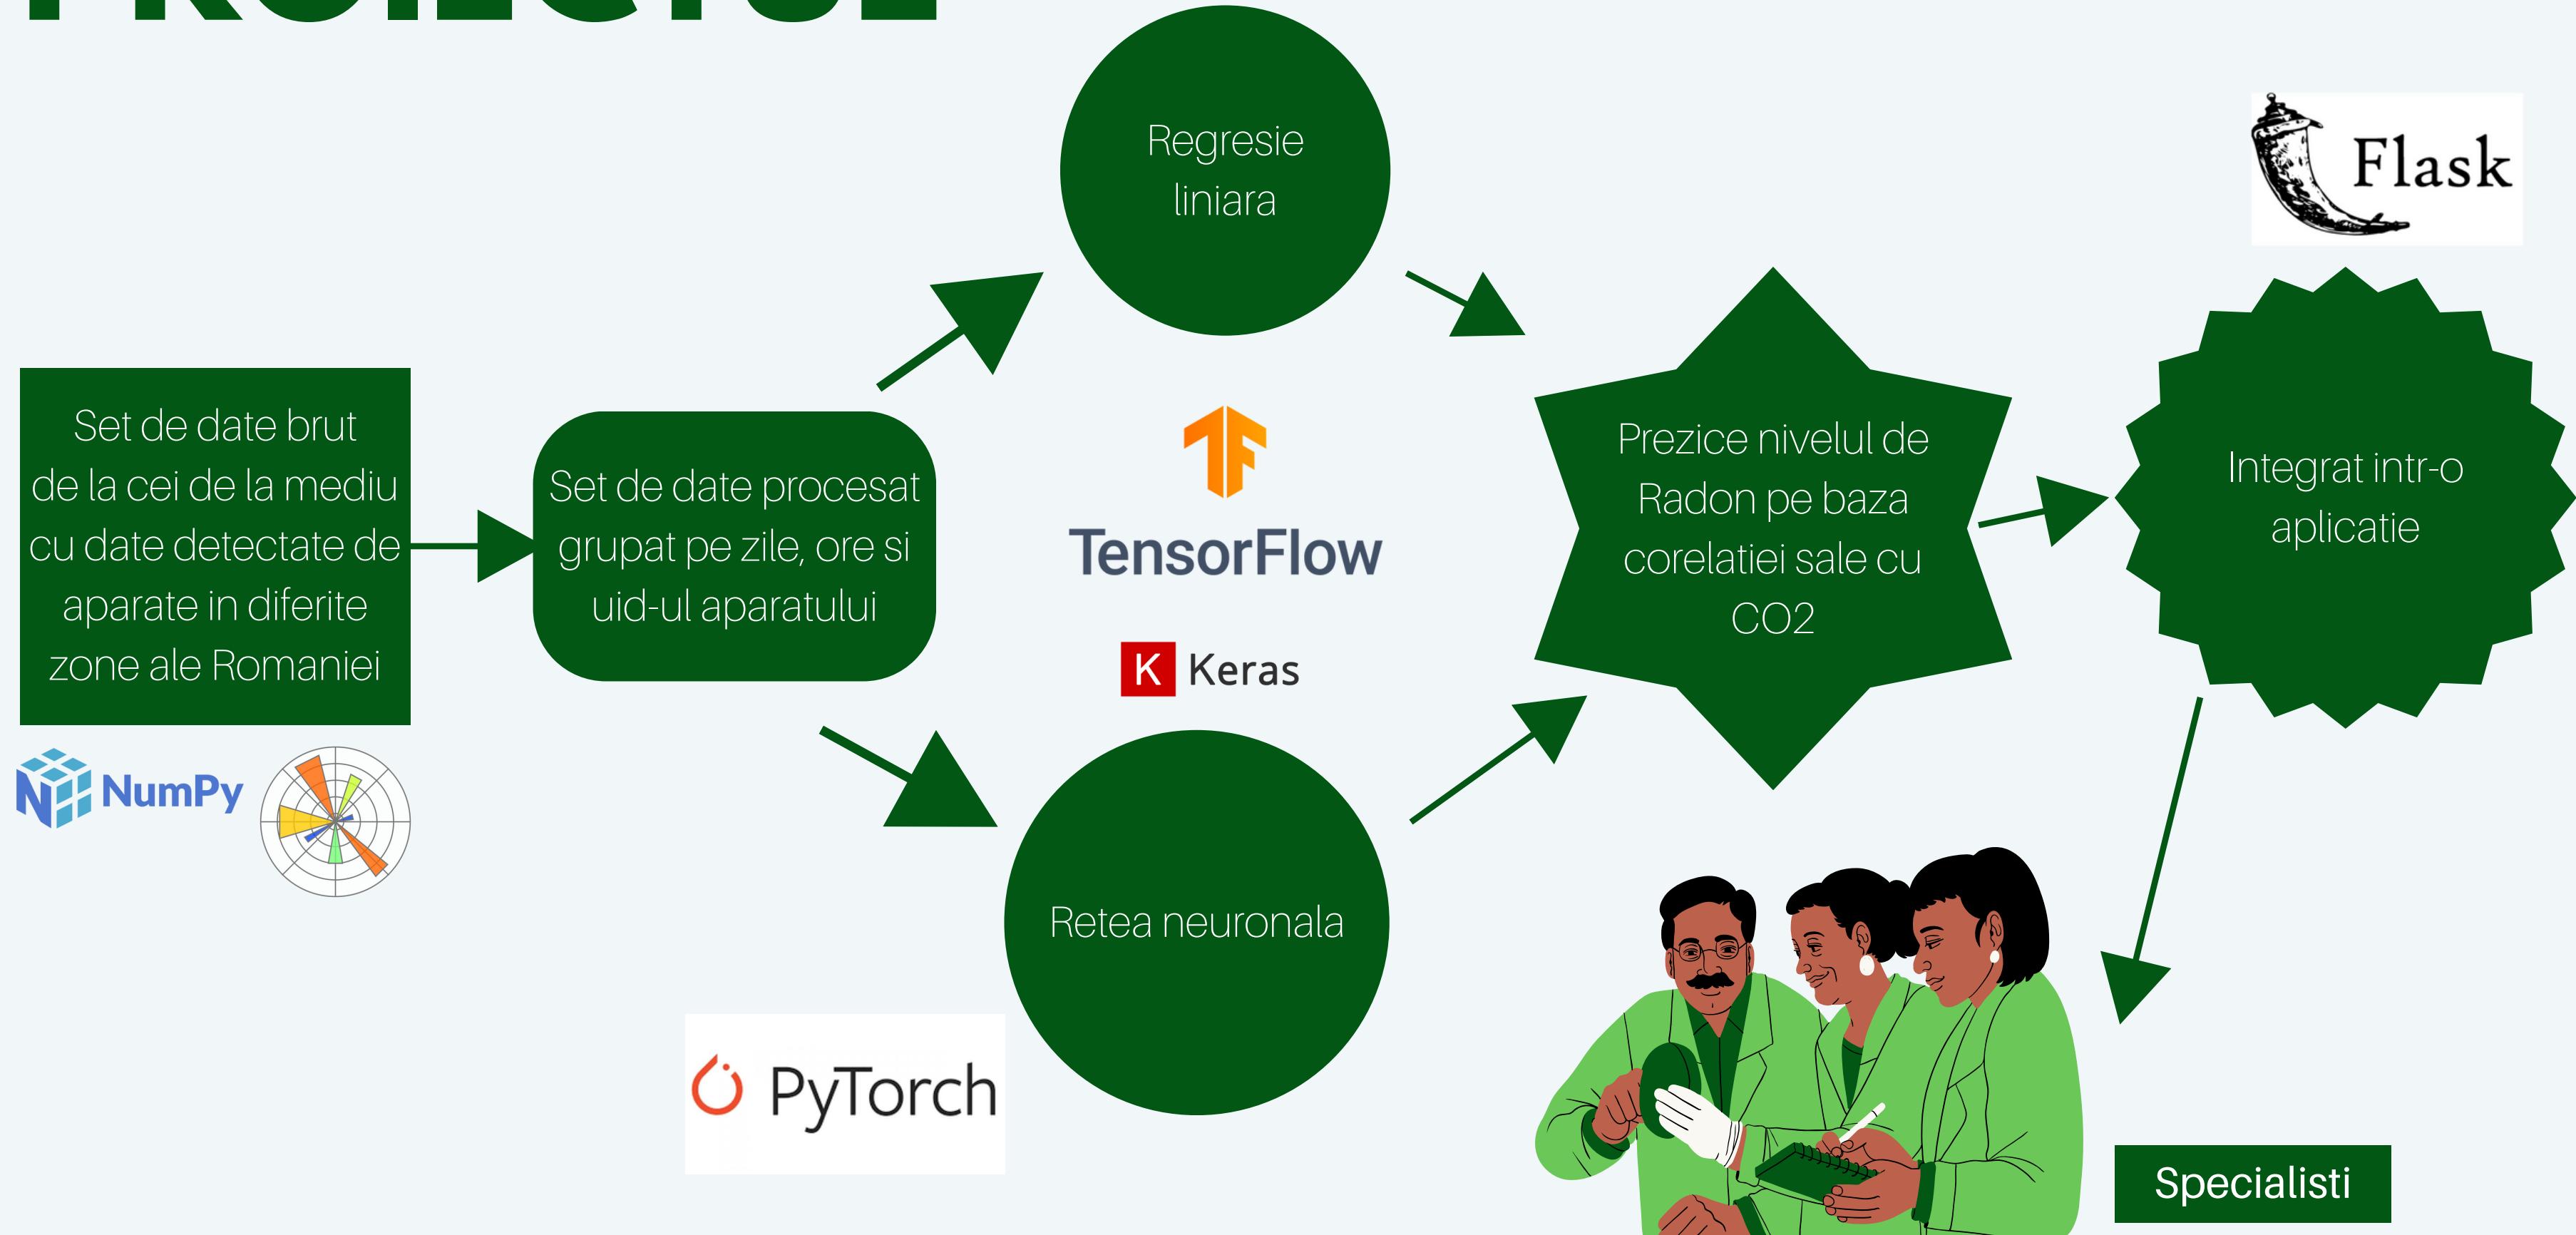
Folosirea Inteligentei Artificiale în detectarea activitărilor seismice oferă niste avantaje semnificative:

- Analiza datelor seismică și geologică folosind Inteligența Artificială identifică modele și tendințe ce semnalează riscul de cutremur sau activitate seismică neobișnuită.
- Predicții și avertismente timpurii folosind algoritmi permit estimări precise și avertizări rapide pentru cutremure iminente sau modificări ale activității seismice.
- Monitorizarea continuă folosind sisteme AI permite observarea în timp real a mișcărilor telurice și a altor parametri relevanți, facilitând intervenții rapide și ajustarea măsurilor de siguranță în funcție de evoluția situației.



1. INTRODUCERE

PROIECTUL



2. METODE EXISTENTE DE REZOLVARE



Analiza seriilor temporale de Radon pe 7 ani în zona Campi Flegrei folosind ANN

Date utilizate

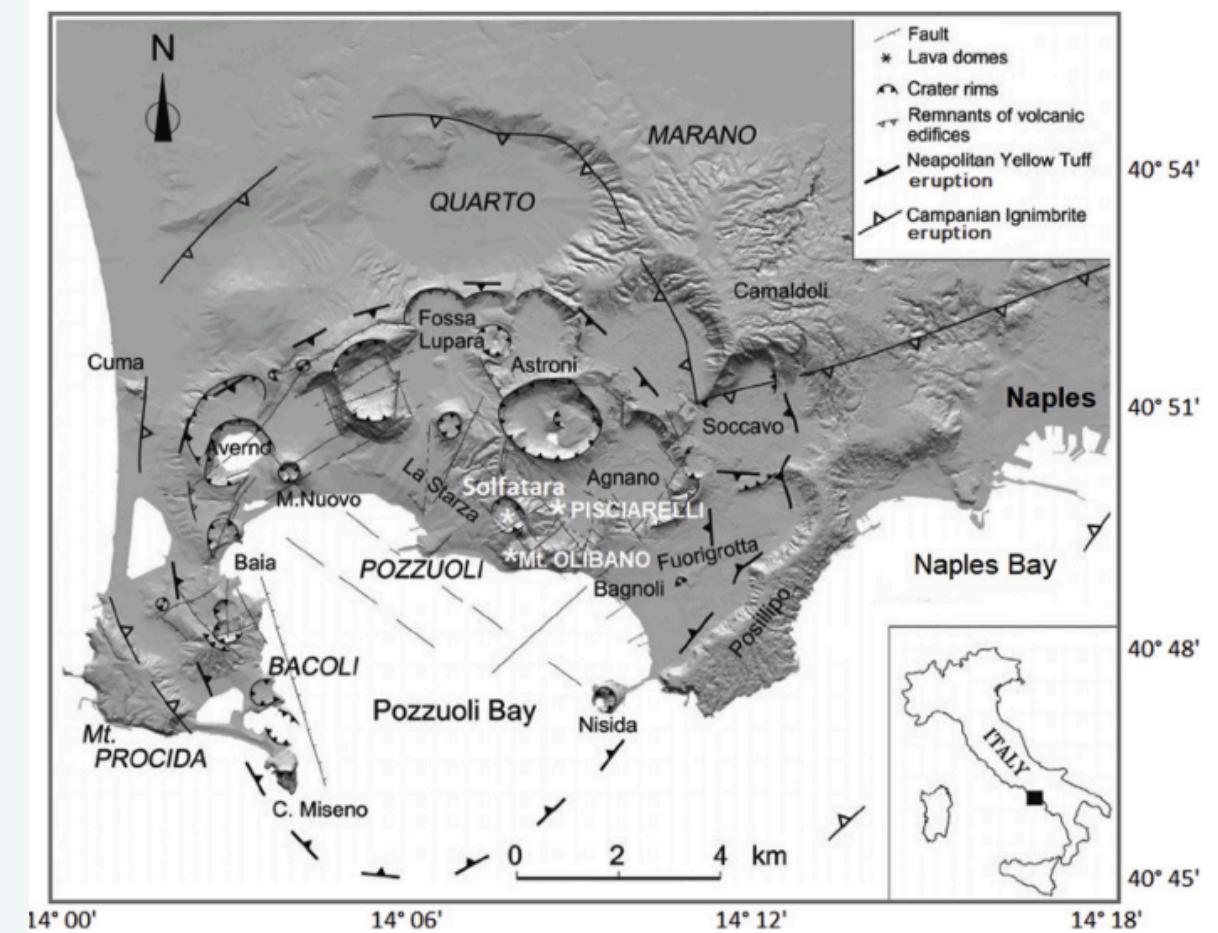
- Locatie: caldera vulcanică Campi Flegrei, Napoli, Italia
- Perioada: 1 iulie 2011 – 31 decembrie 2017
- Tipul datelor: set de date numeric, tabular

Algoritm

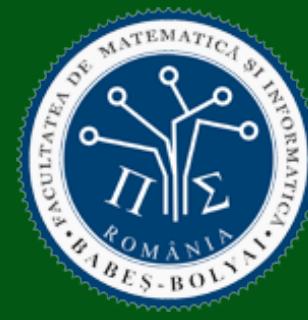
- Retea Neuronala Artificiala (ANN) cu un strat format din 6 neuroni, fiecare reprezentand un parametru diferit: emisiile de gaze din sol, activitatea seismică de fond, concentrația de CO₂, temperatura, umiditatea relativă și presiunea

Rezultate

- Coeficient de corelatie: $p=0.82$
- Performanță: Distributia concentratiei de activitate a Radonului estimată de reteaua neurală a arătat o bună estimare și corelație liniară între semnalele măsurate și cele antrenate.



2. METODE EXISTENTE DE REZOLVARE



Clasificarea Anomalilor pentru Predicția Cutremurelor În Datele Seriilor Temporale de Radon Folosind Stacking și AAIF

Date utilizate

- Locatie: zona de ruptură tectonică din Muzaffarabad, Kasmir, Pakistan
- Perioada: 1 martie 2017 – 28 februarie 2018
- Tipul datelor: concentratia de gaz Radon din sol măsurată în becquereli pe metru cub (Bq/m^3)

Algoritm

- Metodologie cu două etape: un ansamblu de tip stacking și o funcție automata de identificare a anomalilor (AAIF)
- Primul strat foloseste metode precum Regresia Liniara și K-Nearest Neighbors pentru a prezice concentratia SRG și clasifică folosind o Masină de Suport Vectorial (SVM)
- Al doilea strat este funcția AAIF care clasifica seria temporală ca fiind activă/non-activă seismic în funcție de predicții

Rezultate

- Acuratete la testare: intre 0.967 si 0.985 pentru diferite ferestre de timp
- Performanță: Acuratete ridicata in detectarea concentratiilor neobișnuite de radon

SEQUENTIAL DNN

Utilizam un model secential cu 3 straturi dense:

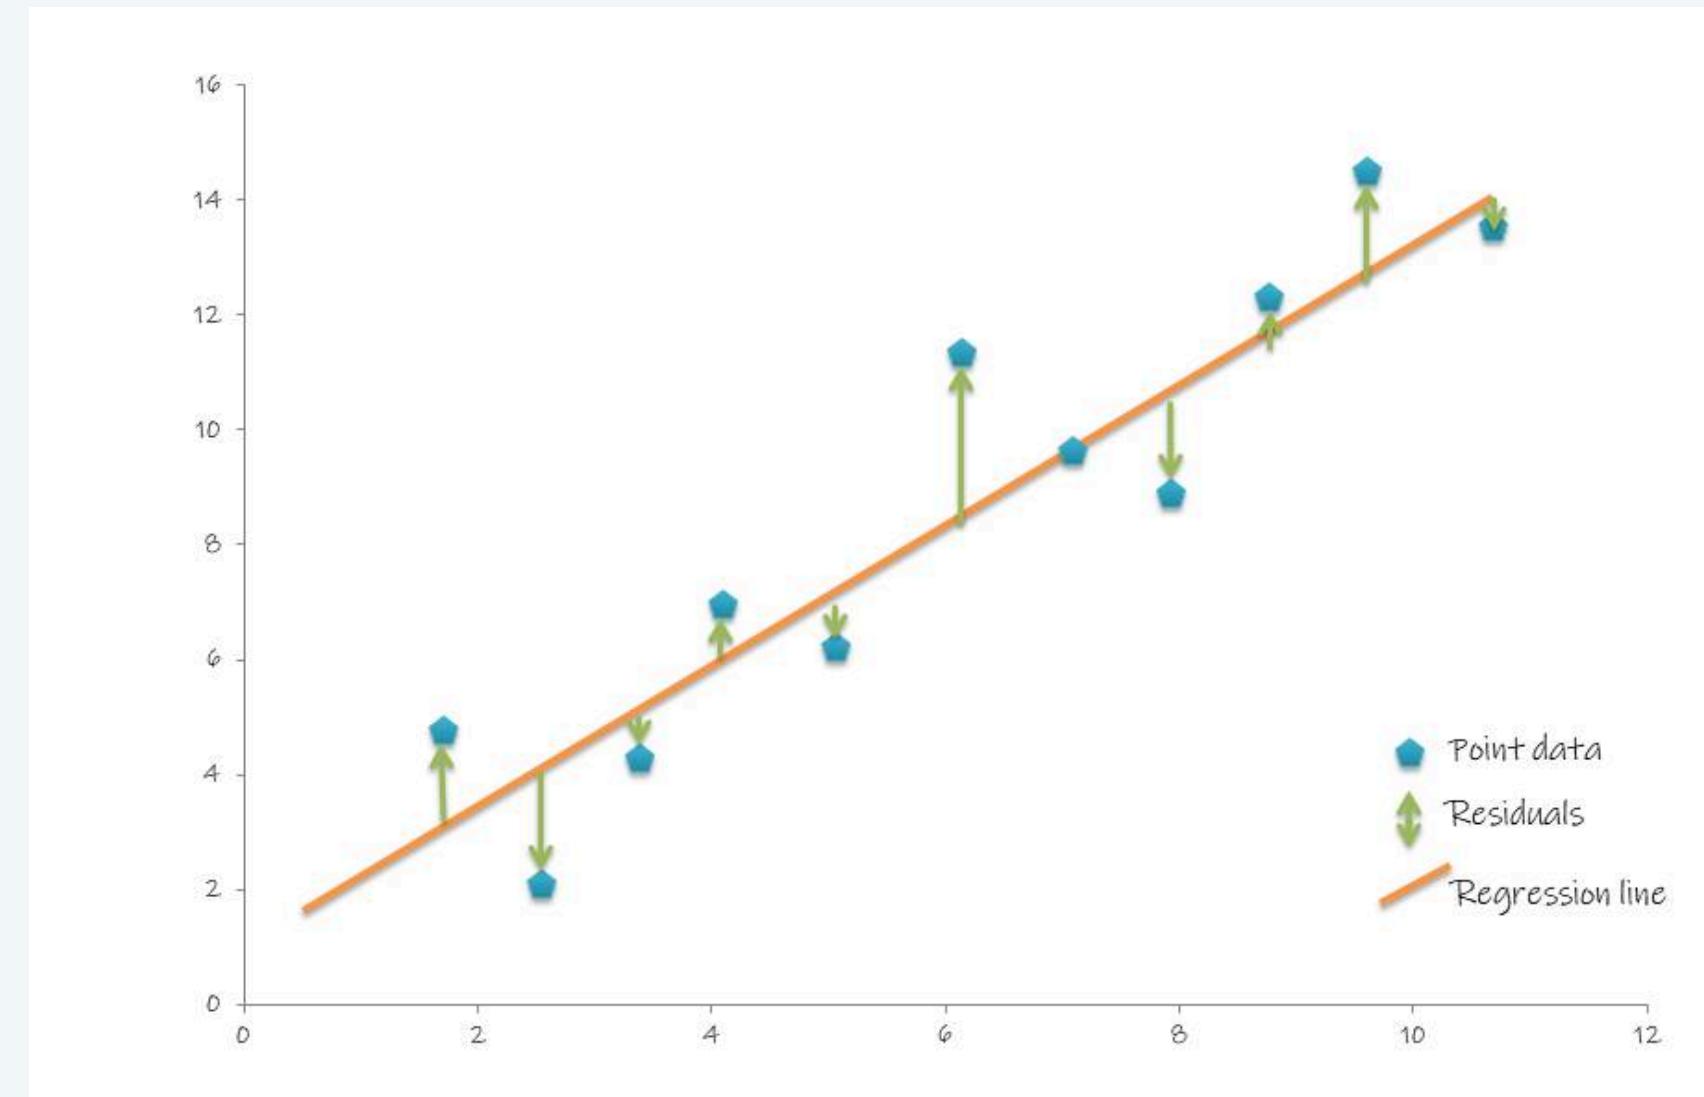
- primul strat: 32 de neuroni, activare ReLU
- al doilea strat: 16 neuroni, activare ReLU
- stratul de iesire: 1 neuron pentru predictie

Procesul de invatare si optimizare:

- optimizator: Adam cu descrestere exponentiala a ratei de invatare incepand de la 0.0001 si scăzând cu 0.9 la fiecare 1000 de pasi
- oprire timpurie: antrenamentul se opreste daca loss-ul nu se imbunatateste pentru 10 epoci consecutive

Metrici folosite pentru evaluarea rezultatelor:

- MSE (eroarea medie patratica): media patratelor diferenței dintre valorile prezise și cele reale
- RMSE (radacina erorii medii patratice) : ofera o interpretare mai directă prin aceeași unitate de măsură ca datele initiale
- R-squared: măsoară cât de bine se potrivesc predicțiile cu valorile reale



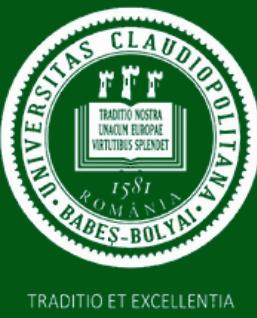
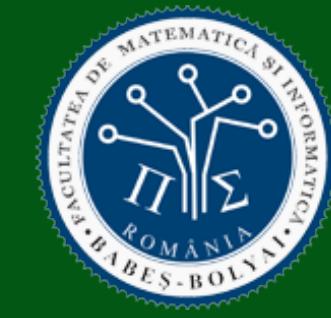
4. REZULTATE EXPERIMENTALE OBTINUTE

SET DE DATE



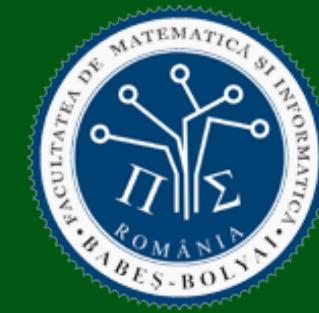
- În cadrul Laboratorului de Încercări Radon „Constantin Cosma” (LiRaCC) de la Universitatea Babeş-Bolyai au fost colectate date prin proiectul RadonControl pentru 25 de judeţe și câteva milioane de date măsurate în 2019 prin diverse aparete specializate.
- Date numerice salvate în format CSV

Stadiu initial	Stadiu Final
<p>Datele erau prezentate cu informații cuprinzând:</p> <ul style="list-style-type: none">• timpul măsurării,• UID-ul aparatului,• gazul măsurat,• valoarea măsurării,• pornire-oprire alarma	<p>Am ales să grupam datele pe:</p> <ul style="list-style-type: none">• ora, zi, luna și an• UID-ul aparatelor pentru a putea prezice pe acele perioade de timp respectiv zonele cele mai predispuze



4. REZULTATE EXPERIMENTALE OBTINUTE

REZULTATE OBTINUTE



TRADITIO ET EXCELLENTIA

Linear regression (exp. 1)

Parametri

- parametrii default
fit_intercept=True,
copy_X=True,
n_jobs=None,
positive=False

Metrici

MSE: 2.704920541514603e-34
RMSE: 1.6446642640717293e-17
MAE: 4.6179672567598306e-18

Performanta

- Rezultate bune

Sequential deep neural network (exp. 2)

- 3 layers
first layer: Dense(32, activation='relu',
input_shape=(1,))
second layer: Dense(16, activation='relu')
third layer: Dense(1)

MSE: 2.366916421469567 x 10^-13
RMSE: 4.865096526760355 x 10^-7
R-squared: 0.9999998490441108

- Rezultate imbunatatite, mai multa flexibilitate si capacitate
mai mare de modelare a datelor complexe. Punct negativ: nu e suportat in aplicatie

Neural Network for regression using pytorch (exp. 3)

- 3 layers
first layer: Dense(32, activation='relu',
input_shape=(1,))
second layer: Dense(16, activation='relu')
third layer: Dense(1)

MSE: 8.723058709736048e-12,
RMSE: 2.9534824715471136e-06,
R-squared: 0.99999986137651

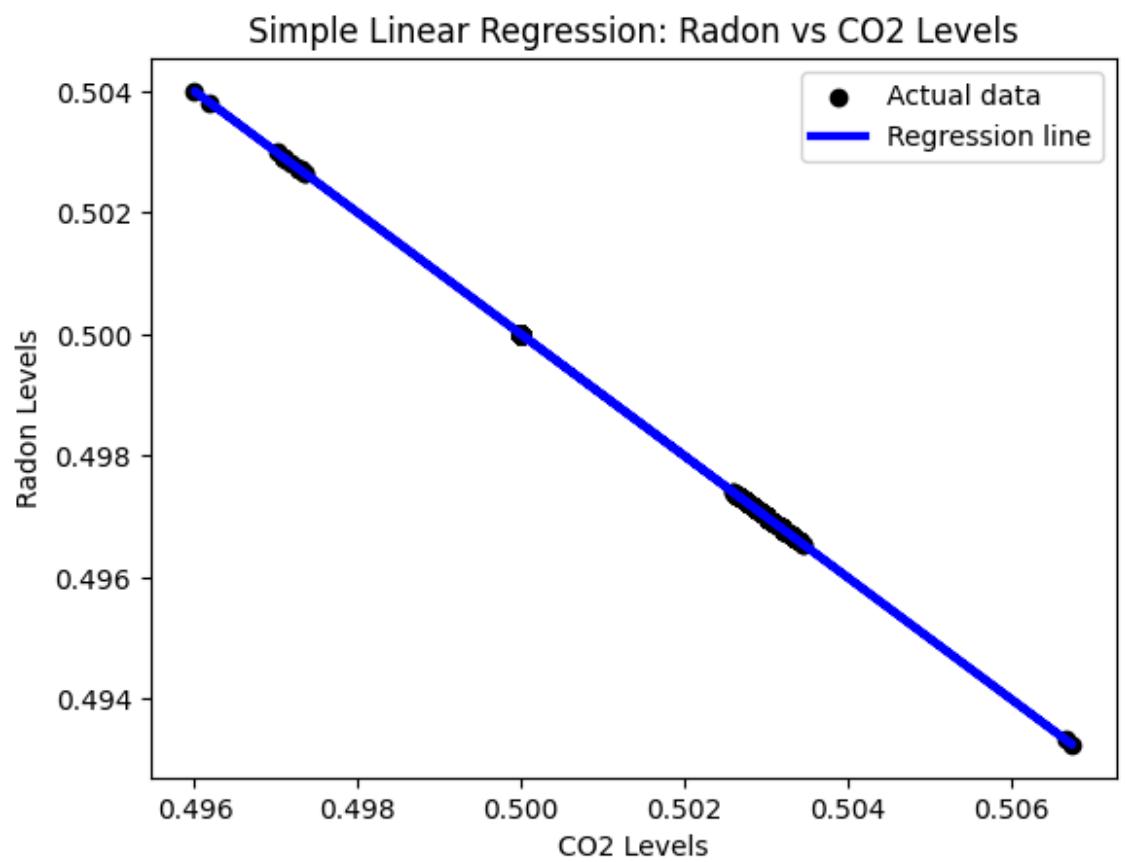
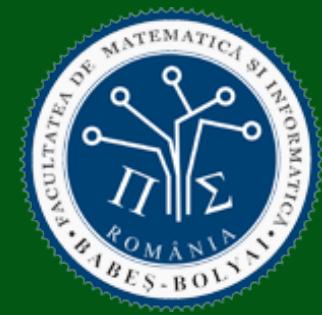
- Rezultate asemanatoare cu experimentul 2, dar integrabil in aplicatie

De ce aceste analize?

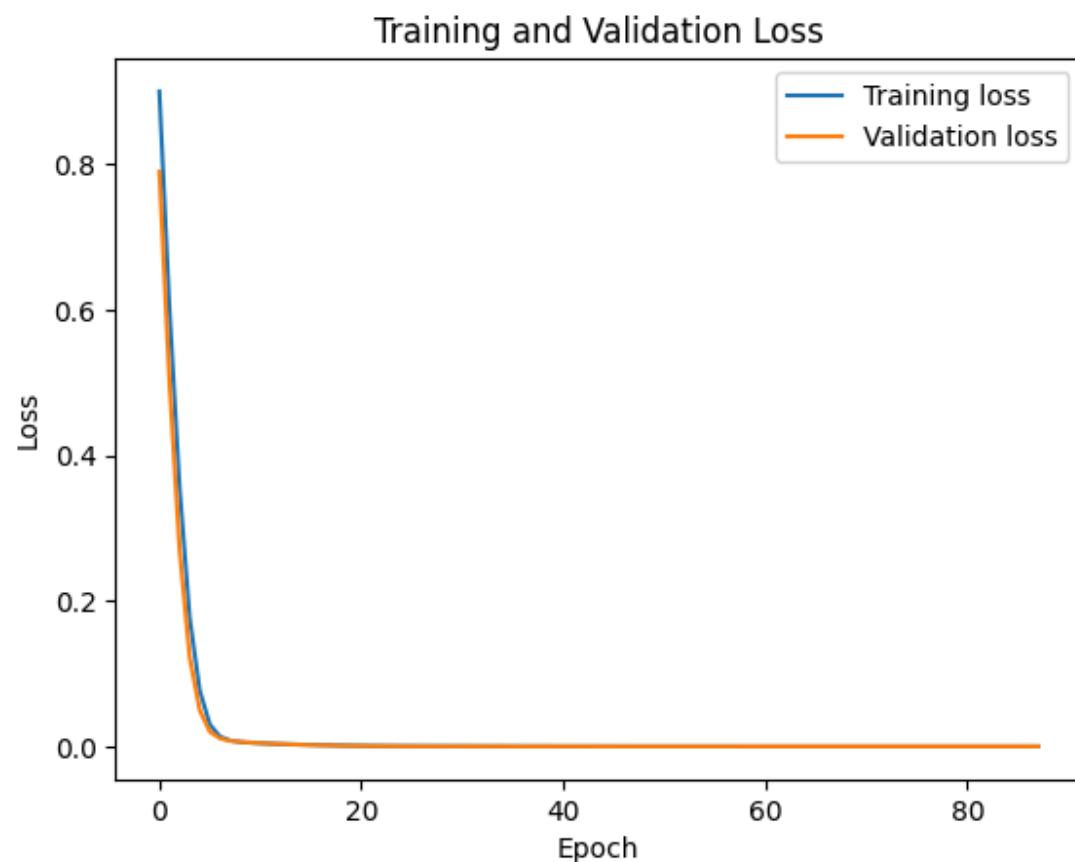
Rezultatele obtinute pot fi analizate de specialistii în domeniu pentru a putea corela și prezice când se întâmplă un cutremur bazat pe valorile de CO₂ respectiv Radon.

4. REZULTATE EXPERIMENTALE OBTINUTE

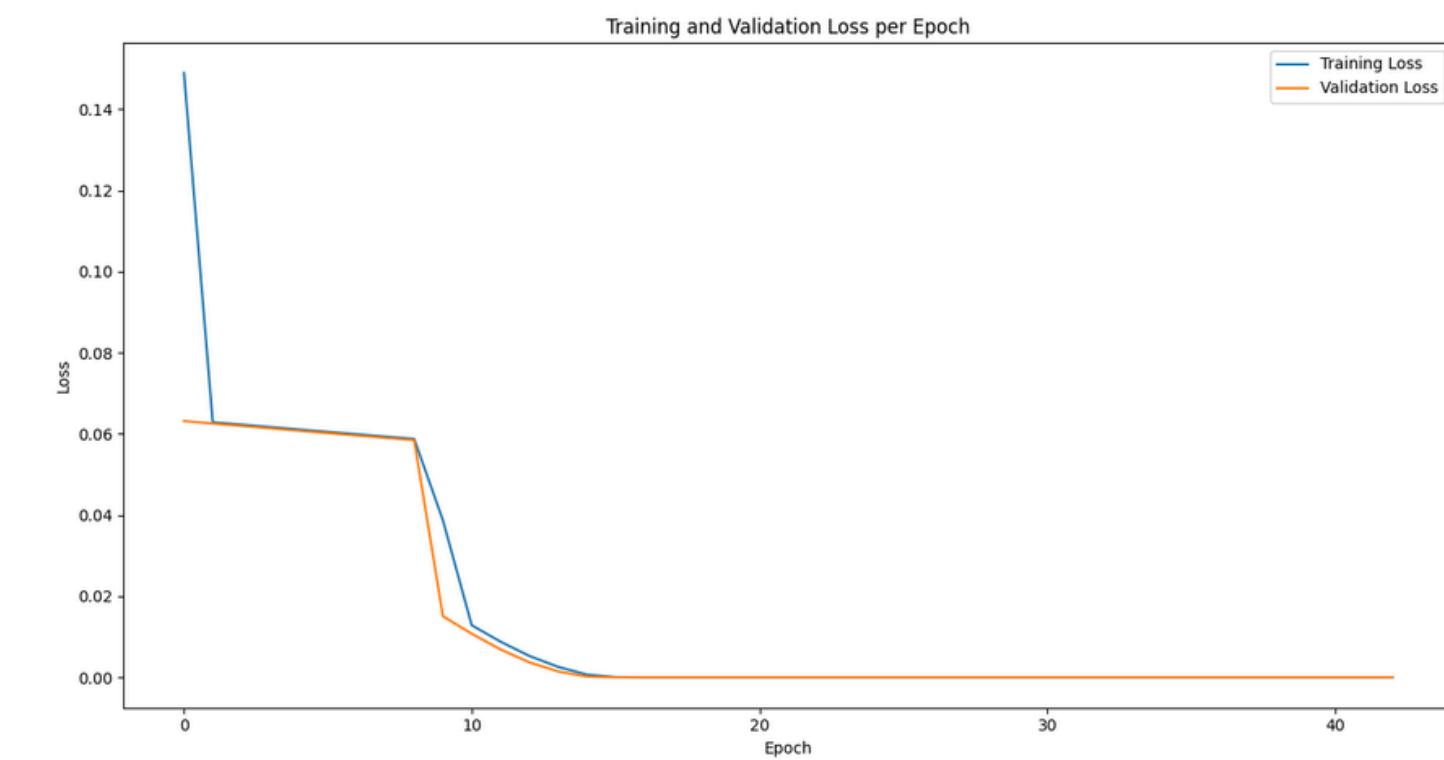
REZULTATE OBTINUTE



Exp. 1



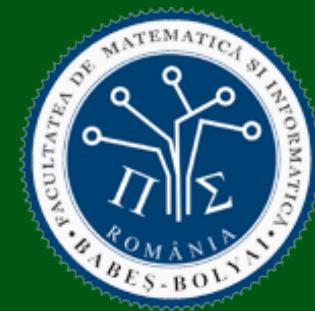
Exp. 2



Exp. 3

4. REZULTATE EXPERIMENTALE OBTINUTE

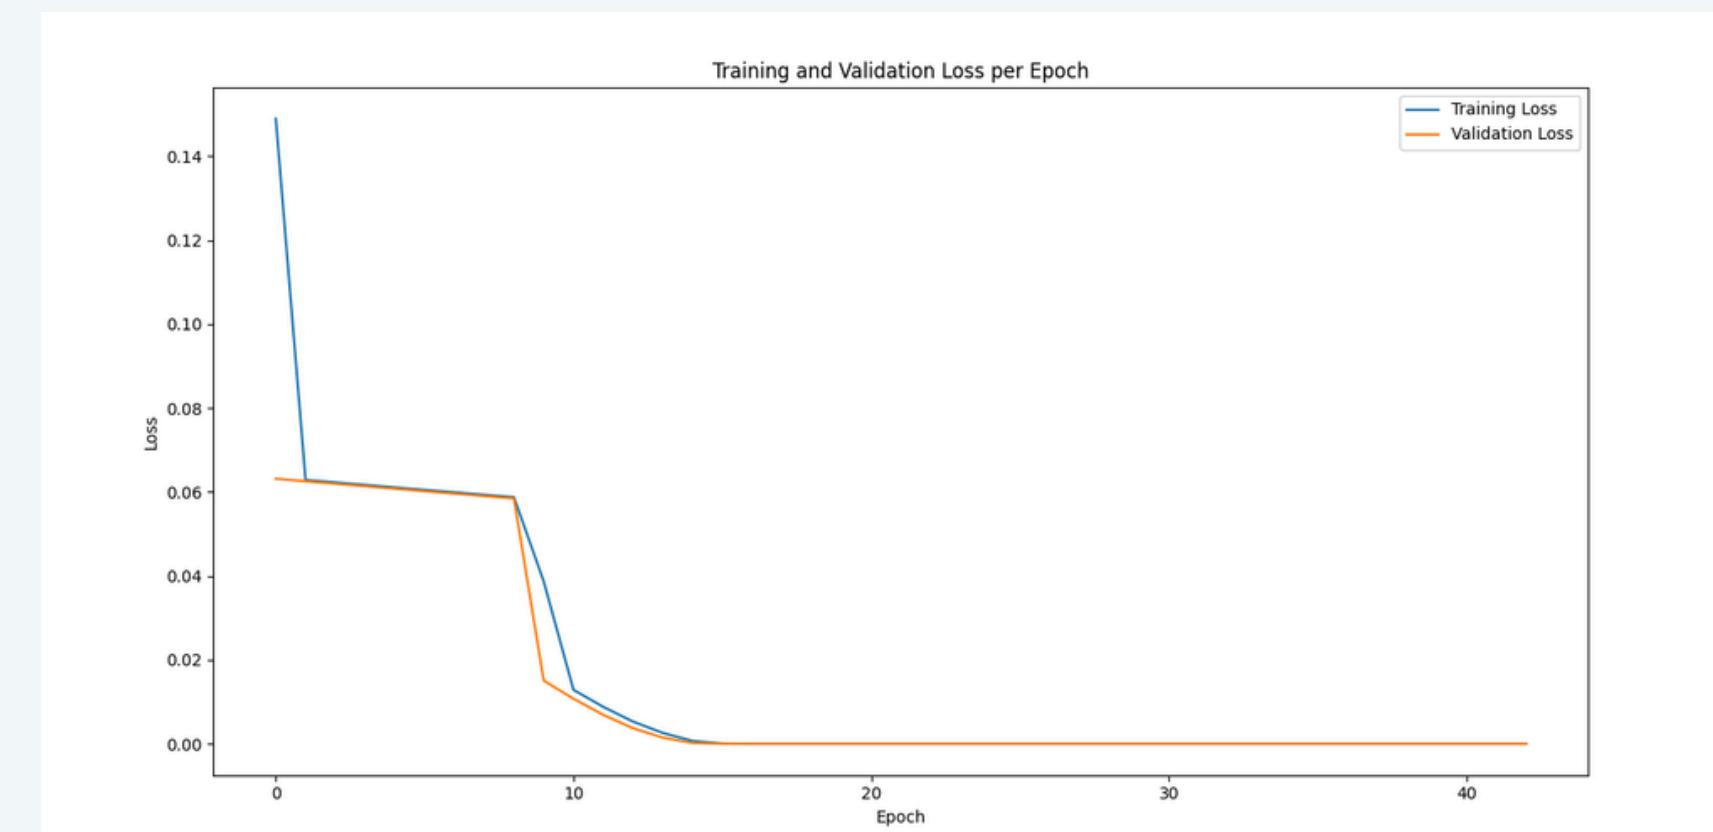
ANALIZA REZULTATELOR



TRADITIO ET EXCELLENTIA

Concluzii:

Performanța modelului de rețea neuronală din experimentul 2 este mai bună, apropiindu-se de o valoare perfectă pentru R-squared(1), care indică o potrivire aproape perfectă a modelului pe date. RMSE și MSE sunt foarte mici, ceea ce sugerează că erorile de predicție sunt neglijabile. Experimentul 3 este foarte asemănător cu experimentul 2, iar acesta permite integrarea cu aplicația.



Valori metrici:

MSE: $2.366916421469567 \times 10^{-13}$

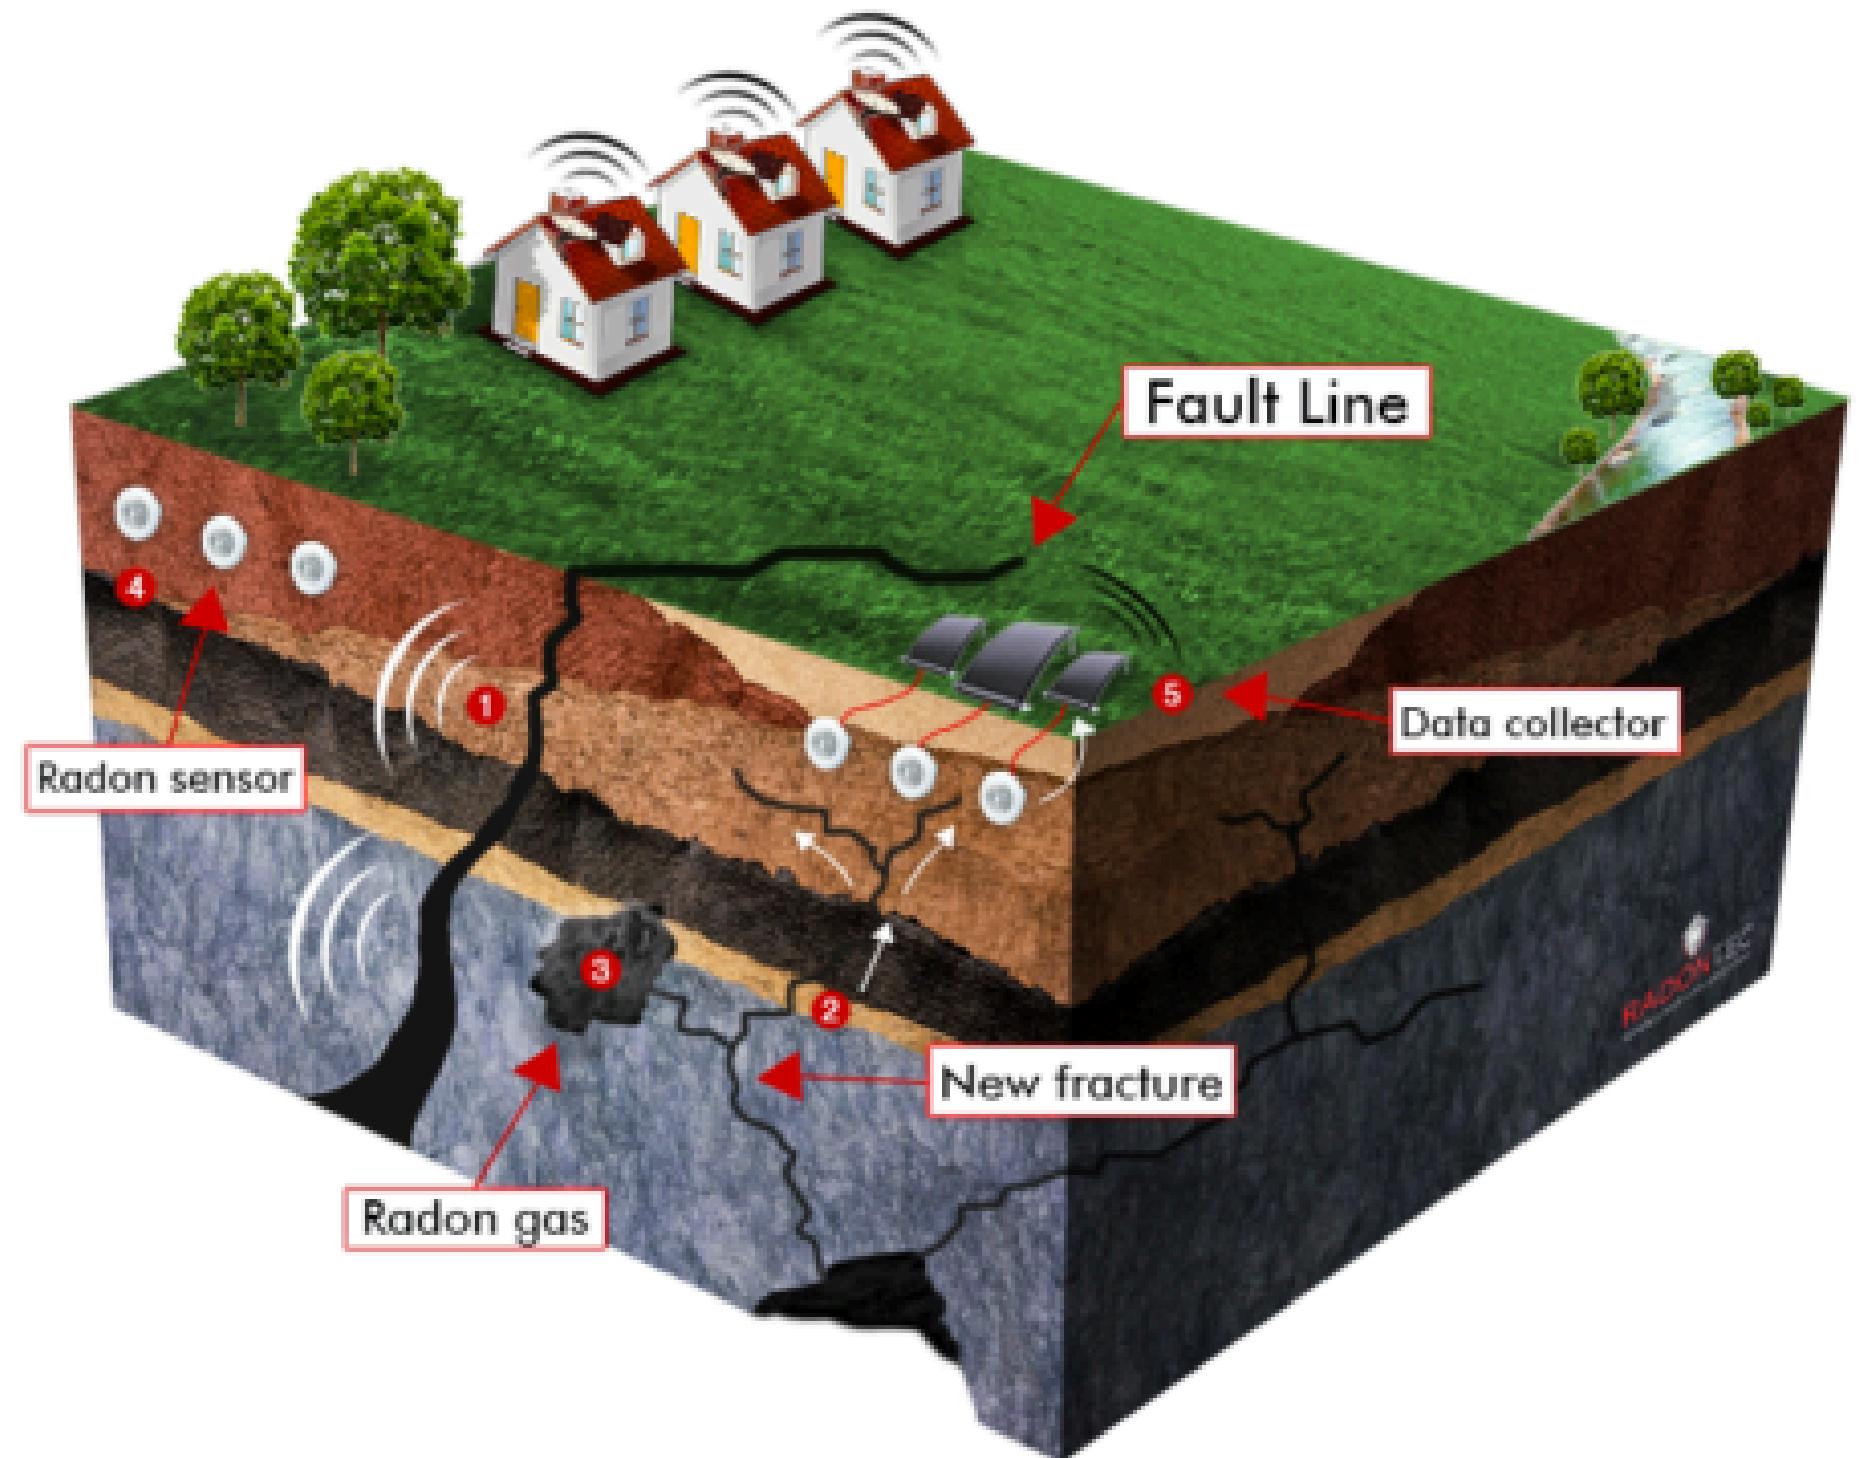
RMSE: $4.865096526760355 \times 10^{-7}$

R-squared: 0.999998490441108

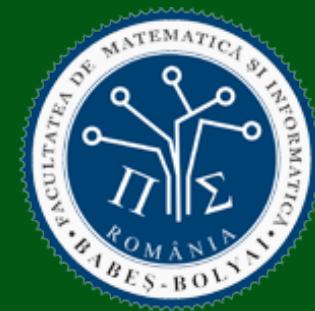
CE AM PUTEA FACE MAI DEPARTE

Putem:

- dezvolta modele mai complexe care să poată detecta apariția cutremurelor (momentan depindem de specialiști să citească datele)
- îmbunătăți modelul curent
- analiza date și din afara României prin diverse colaborări



LINK-URI SI CITATII



TRADITIO ET EXCELLENTIA

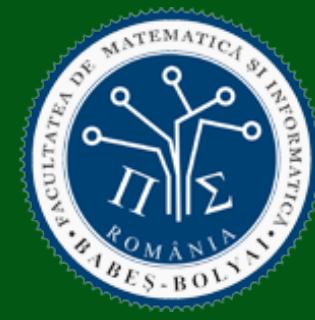
Articole științifice:

1. Analysis of 7-years Radon time series at Campi Flegrei area (Naples, Italy) using artificial neural network method; *F. Ambrosino a b, C. Sabbarese a b, V. Roca b, F. Giudicepietro c, G. Chiodini*
2. Anomaly Classification For Earthquake Prediction In Radon Time Series Data Using Stacking And Automatic Anomaly Indication Function; *Adil Aslam Mir, Fatih Vehbi C, Elebi, Muhammad Rafique, M. R. I. Faruque, Mayeen Uddin Khandaker, Kimberlee Jane Kearnott, And Pervaiz Ahmad*
3. CO₂ and Radon Emissions as Precursors of Seismic Activity. *Earth Syst Environ 5; D'Incecco, S., Petraki, E., Priniotakis, G. et al.*

Imagini:

- 1.<https://radontec.de/earthquake-early-warning-with-radon-sensor-technology>
- 2.<https://hatarilabs.com/ih-en/how-to-calculate-the-root-mean-square-error-rmse-of-an-interpolated-ph-raster>
- 3.<https://www.digi24.ro/stiri/externe/cutremurul-din-japonia-a-largit-cu-175-de-metri-linia-de-coasta-a-peninsulei-noto-2640627>
- 4.<https://www.digi24.ro/stiri/actualitate/alerta-de-cutremur-in-turcia-mai-multe-seisme-de-suprafata-au-zguduit-regiunea-tokat-2766009>
- 5.<https://www.times-standard.com/2024/02/17/lori-dengler-artificial-intelligence-in-the-earthquake-and-tsunami-world/>

COD SURSA + CAPTURA



TRADITIO ET EXCELLENTIA

<https://github.com/taniasasaran/QORn>

CO2 - Radon Correlation and Prediction

Enter CO2 value to predict radon value.

CO2:

Predict

Prediction Result

Predicted radon value: 4291.611328125

CUM PUTEM PROTEJA FIINTELE DE CUTREMURE?

TANIA SASARAN
BIANCA SZEKELY
MARA VALEAN
JACLINA-IANA BULAT
MARK DOSZLOP

